

Extending Scale BB from All-Cause to Cause-Specific Mortality: A Scenario Generator for Disease-Contingent Insurance under Economic-Value-Based Valuation

2026-07-31

目次

§1 序論 (Introduction)	2
1.1 背景 — 二つの転換	3
1.2 本研究のアプローチと新規性	3
1.3 発見の構造と本論文の構成	4
§2 先行研究と規制要件 (Related Work and Regulatory Requirements)	5
2.1 SOA (2012) Scale BB と 2D → 1D 縮約の設計思想	5
2.2 APC モデルと疾病率モデリングの先行研究	5
2.3 経済価値ベース規制が要求するシナリオ構造 (ICS / IFRS 17 / Solvency II)	6
§3 データと手法 (Data and Methodology)	8
3.1 データと対象疾病	8
3.2 Scale BB 拡張アルゴリズム	10
3.3 APC コホートペナルティ拡張	13
3.4 ベースライン手法と評価指標	15
§4 検証設計 (Backtest Design)	17
4.1 検証の枠組み — fit → project → validate	17
4.2 3 cutoff 設計とその意図	17
4.3 検証セル数と統計的含意	19
4.4 検証で測るもの (§3.4 の適用)	19
4.5 再現	19
§5 Results I — 点予測精度の検証結果 (Point-Forecast Accuracy)	21
5.1 Scale BB-D 単体の点予測精度 ($y_c = 2014$)	21
5.2 ベースライン比較 ($y_c = 2014$) — 全 24 セルで劣後	23
5.3 COVID-19 期を学習に含めた場合 ($y_c = 2021/2022$)	24
5.4 総括 — 消極的結論と次章への転換	25
§6 Results II — 方向性的中率の発見 (The Directional Accuracy Finding)	26

6.1 $y_c = 2014$ の方向性的中率 — 主要 6 疾病で 77.7–95.0%	26
6.2 3 cutoff 横断 — 学習期間によらず方向を捉えるか	26
6.3 ベースライン比較 — 方向情報を持つ手法は限られる	27
6.4 乖離は何を意味するか — 構造モデルと点予測器の本質的差異	28
6.5 方向反転疾病の扱い — キャリブレーションの適用範囲と限界	29
§7 Repositioning — シナリオ生成器への再定位 (Scale BB-D as a Scenario Generator for ICS / IFRS 17)	32
7.1 発見の読み替え — 3 つの構造的性質	32
7.2 規制シナリオへの実装対応	32
7.3 ベースライン手法が同じ役割を担えない理由	33
7.4 ESG との対比 — 疾病リスク軸の決定論的シナリオ生成器	34
7.5 導入負担への予告	34
7.6 特定疾病死亡保障への直接適用 — 二層の適用可能性	34
§8 財務インパクトのデモ (Financial Impact Demonstration)	36
8.1 デモの設計 — 簡易モデルと ESR 実装仕様への準拠	36
8.2 シナリオとモデルポイント	37
8.3 結果 — BEL 感応度の一表	37
8.4 考察 — トrendショックとレベルショックの対比	38
8.5 拡張 — 生命保険リスク所要資本と保険負債の簡易計算	39
§9 実務ガイドライン (Practical Implementation Guidelines)	41
9.1 キャリブレーション・チューニング指針	41
9.2 導入負担の分析 — 五つの論拠と段階的導入パス	42
9.3 既存システムへの組み込み実績	43
§10 限界と今後の課題 (Limitations and Future Work)	44
10.1 データの代理性 — 適用範囲の限定と発生率での直接検証	44
10.2 長期予測精度の検証可能性 — 蓄積待ちではなくシナリオ化で扱う	44
10.3 疾病別キャリブレーションの体系化	45
10.4 財務デモの簡易性と実務モデルでの再実行	45
10.5 確率論的拡張	45
§11 結論 (Conclusion)	46

§1 序論 (Introduction)

本論文は、米国アクチュアリー会 (SOA) が 2012 年に公表した死亡率改善スケール Scale BB を全死因死亡率から死因別 (疾病別) 死亡率へ拡張し、10 年間のバックテストによる検証を経て、経済価値ベースの保険負債評価 (国際資本基準 ICS / 国際会計基準 IFRS 17、日本では経済価値ベースのソルベンシー規制 ESR) が要求するシナリオ生成器として位置づけるものである。本章では、この問題設定を生んだ二つの環境変化 (§1.1)、本研究のアプローチと新規性 (§1.2)、そして本論文を貫く発見の構造と各章の構成 (§1.3) を述べる。なお表記について、SOA 原典のスケールを Scale BB、本研究の拡張フレームワークを Scale BB-D(D は Disease、疾病別への拡張を表す) と書き分ける。

1.1 背景 —二つの転換

疾病率の構造変化。COVID-19 パンデミックは、近年最大の死亡率・平均余命ショックであった。その影響は 2020 – 2022 年の直接的な超過死亡にとどまらず、受療行動の変化・医療提供体制の逼迫・長期的健康影響を通じて、疾病別の死亡率・発生率のトレンドにも及ぶ。OECD (2023) は、パンデミックが死亡率改善仮定を不安定化させたこと、ショックの主要部分は一時的とみなしつつも長期的な健康影響の不確実性が大きいことを指摘し、将来の改善率モデルには透明性と将来期待との整合が求められるとした。米国アクチュアリー・アカデミー (AAA) の実務ノートも、外生ショック後のアサンプション設定において、静的表と世代別テーブルの使い分け、長期改善率と短期から長期への移行の調整、感応度分析と判断の文書化の重要性を強調する。実際、本研究のバックテストでも、COVID-19 ショックを学習に含めるか否かで同一モデルの検証 MAPE(平均絶対パーセント誤差、Mean Absolute Percentage Error) は 6~8 倍変わる (§5.3)。静的な予定率表に依拠してきた第三分野 (医療・疾病保障) のアサンプション実務にとって、「過去の経験率がそのまま続く」という前提の危うさが顕在化した局面である。

日本における資本規制環境の転換。同じ時期に、保険負債・資本の評価枠組みは経済価値ベースへの転換を完了しつつある。EU の Solvency II(2016 年適用)、国際会計基準 IFRS 17(2023 年発効) に続き、国際資本基準 ICS が 2024 年 12 月に採択され、日本では経済価値ベースのソルベンシー規制 (ESR) が 2025 年度から適用開始となった。本論文の執筆時点は、まさに ICS 発効・ESR 適用年度にあたる。これらの枠組みに共通するのは、負債・資本の計算が単一のベストエスティメート点予測ではなく、ベースシナリオと規定されたストレスシナリオ群 (レベル・トレンド・カタストロフィ)、感応度開示、ORSA(リスクとソルベンシーの自己評価、Own Risk and Solvency Assessment) ストレスで構成される点である (§2.3 で詳述)。

疾病リスク軸の空白。二つの転換の交点に、実務の空白がある。経済リスク軸には ESG(経済シナリオジェネレーター、Economic Scenario Generator) という体系的なシナリオ供給装置が整備されている一方、疾病リスク軸のアサンプション実務は静的な予定率表に一律の係数を乗じる方式が主流であり、トレンドショック—改善率という時間構造を持つ変更—を陽に表現できない。すなわち、いま実務が必要としているのは「より精度の良い単一の点予測」ではなく、「同一のベースから内的整合性を保って複数のシナリオを生成する仕組み」である。本論文の問題設定はここにある。

1.2 本研究のアプローチと新規性

アプローチ。Scale BB は、全死因死亡実績を年齢 × 暦年の 2 次元で平滑化して改善率を抽出し、直近実績の改善率を長期想定改善率 L へ収束年 P にかけてブレンドする、解釈可能な少数パラメータを持つ実務スケールである (§2.1)。本研究はこの枠組みを死因別死亡率へ適用できるよう拡張し (§3.2 – 3.3)、厚生労働省「人口動態統計」の死因別死亡率 (1950 – 2024 年、8 疾病 × 3 性別 × 21 年齢区分) を入力として、学習打ち切り年を 3 通りに振ったバックテスト (§4) で点予測精度と方向性的中率の両面から検証した。

新規性は二層をなす。第一に (新規性 A)、Scale BB 系の改善スケールを死因別死亡率へ拡張すること自体である。原典 Scale BB もその後継 (MP 系列・CMI モデル) も対象は一貫して全死因死亡率であり、死因ごとに異なる改善トレンド・期間ショック・世代効果を同一の枠組みで分離抽出する体系的拡張は、筆者らの知る限り提示されていない (§2.1 – 2.2)。第二に (新規性 B)、特定疾病死亡保障への直接適用である。三大疾病死亡保障・がん死亡保険・死因別の疾病死亡特約など、死因別死亡を給付事由とする商品では、本研究が検証した死因別死亡率がアサンプションそのものとなり、シナリオ生成器を直接適用できる。一方、医療保険の疾病発生率に対しては、公開統計に長期の発生率パネルが存在しないため、死因別死亡率は方法論検証の代理として

働く (§3.1.3)。この二層——代理と直接——の区別は本論文全体を貫く前提である。なお、罹患後死亡率 (致命率) の予測は本研究の範囲外であり、いかなる形でも主張しない (§3.1.3、§10)。

1.3 発見の構造と本論文の構成

本論文の構成は、当初の検証計画がそのまま成功物語として完結したものではなく、消極的結論から想定外の発見を経て新知見に至る三段の構造を持つ。先に骨格を示す。

当初目的と消極的結論 (§5)。当初の目的は、Scale BB-D 拡張が疾病率の点予測に有用かの検証であった。結果は明確な否である。Scale BB-D は全 cutoff・全 24 セル (8 疾病 × 3 性別) で最良の単純ベースラインに MAPE で劣後する (学習打ち切り 2014 年で +16~+44pp)。

想定外の発見 (§6)。ところが、同じモデルの出力を「変化の向き」で測り直すと様相が一変する。主要 6 疾病の方向性的中率は 77.7–95.0% に達し、方向情報を構造的に持たない、あるいは偶発的にしか持たないベースライン手法を大きく上回る。点予測を外しながら方向を当てる——この乖離は偶然ではなく、長期トレンドを尊重し観測終端のノイズをあえて無視するという設計の帰結である (§6.4)。

新知見への翻訳 (§7–§9)。§2.3 で整理するとおり、経済価値ベース評価が中心的に要求するのは点予測の精度ではなくシナリオ間の内的整合性であり、その基礎条件は、モデルが出力する改善率の方向性が事前に検証されていることである。§7 はこの観点から Scale BB-D をシナリオ生成器として再定位し、§8 は ESR の実装仕様 (無リスク金利カーブ・告示ストレス係数) に準拠した BEL (最良推計負債、Best Estimate Liability) 感応度デモで実務的意義を数値化する。とりわけ、規制の一律レベルショックの影響が加入年齢によらずほぼ一定 (+17~19%) であるのに対し、トレンドショックは若年加入で規制ショックの約 1.7 倍に達する年齢勾配を持つという対比 (§8.4) は、一律係数の現行実務では捉えられないリスクの年齢構造を示す。§9 は導入時のキャリブレーション指針と導入負担を論じる。

一文で要約すれば、本論文の主張は次のとおりである。Scale BB-D の死因別死亡率への拡張は、短期点予測では単純ベースラインに劣後するが、バックテストで方向性が検証された改善率 $i^*(x, y)$ を陽に出力し、経済価値ベース評価が要求するシナリオ生成器として構造的優位を持つ。そして死因別死亡率は、医療保険の疾病発生率に対しては方法論検証の代理、特定疾病死亡保障に対しては対象そのものであり、後者では代理の限界を負わずに直接適用できる。

以下、§2 で先行研究と規制要件、§3 でデータと手法、§4 で検証設計、§5 で点予測精度の結果、§6 で方向性的中率の発見、§7 でシナリオ生成器への再定位、§8 で財務インパクトのデモ、§9 で実務ガイドライン、§10 で限界と今後の課題、§11 で結論を述べる。

まず次章では、出発点となる原典 *Scale BB* の設計思想と、本研究の評価軸を規定する規制要件——単一の点予測ではなく内的整合的なシナリオ群を要求する構造——を整理する。

§2 先行研究と規制要件 (Related Work and Regulatory Requirements)

本章では、本研究の出発点となる先行研究と、本研究の評価軸を規定する規制要件を整理する。§2.1 で原典 SOA (2012) *Mortality Improvement Scale BB* の設計思想を確認し、原典が全死因死亡率を対象とすることに対して本研究の死因別拡張 (新規性 A) を対置する。§2.2 で APC(Age-Period-Cohort) モデルと疾病率モデリングの先行研究を概観し、本研究が埋めるギャップを特定する。§2.3 では ICS / IFRS 17 / Solvency II が保険負債評価に要求するシナリオ構造を整理する。規制要件を本論 (§5 以降) に先立ってここに置くのは、本研究の評価軸が「点予測の精度」だけでは閉じないこと——規制が中心的に要求するのは単一の点予測ではなく、内的整合性のある複数シナリオであること——を、結果の解釈に入る前に確認しておくためである。

2.1 SOA (2012) Scale BB と 2D → 1D 縮約の設計思想

Scale BB は、米国アクチュアリー会 (SOA) が従来の一次元死亡率改善スケール Scale AA の限界を踏まえて 2012 年に提示した代替スケールである。その設計は次の 3 要素からなる。

1. 二次元での改善構造の把握。米国社会保障庁 (SSA) の全死因死亡実績を年齢 × 暦年の二次元 (2D) で P-スプライン平滑化し、改善率の面 (surface) として抽出する。ヒートマップ上の縦パターン (期間効果: 例 インフルエンザ流行) と斜めパターン (コホート効果: 例喫煙習慣の世代差) を識別し、期間ショックをモデルに取り込む発想がここで明示された。
2. 長期改善率へのブレンド。直近実績の改善率をそのまま外挿するのではなく、固定起点 (2005 年) から収束年にかけて長期想定改善率 1.0%/年へ線形に移行させる (コホート収束期間 10 年。原論文 §7.4 のブレンド関数 $h(y)$)。直近トレンドと長期想定を明示的に接続するこの構図は、英国 CMI の Mortality Projections Model が採る「直近推定改善率から長期想定改善率へのブレンド」と同系の思想である。
3. 実務互換性のための 1D 縮約。2D の情報を、金銭影響が近似的に等価となる年齢一次元 (1D) のスケールに落とし、評価ソフトウェアの改修なしで利用できる形で提供する。Scale BB が「暫定スケール」と自称しつつ広く参照されたのは、この実務導入の摩擦を下げる設計による面が大きい。

なお SOA はその後、後継の MP-2014 以降で年齢 × 暦年の二次元スケールを年次更新する体制へ移行しており、2D で改善構造を捉える枠組み自体は米国実務の標準となっている。

本研究との対置 (新規性 A)。原典 Scale BB もその後継スケールも、対象は一貫して全死因死亡率である。死因別 (疾病別) の死亡率に対して、死因ごとに異なる改善トレンド・期間ショック・世代効果を同一の枠組みで分離抽出する体系的拡張は、筆者らの知る限り提示されていない。本研究はこの拡張を行い (§3.2–3.3)、さらにその出力を §2.3 で述べる規制要件のシナリオ生成に接続する (§7)。拡張後のフレームワークが持つ二重の適用可能性——医療保険の疾病発生率に対する方法論検証の代理、特定疾病死亡保障に対する直接のアサンプション——は §3.1.3 で定義する。

2.2 APC モデルと疾病率モデリングの先行研究

死亡率モデリングの二系譜。死亡率の将来予測には大別して二つの系譜がある。第一は確率論的モデルの系譜であり、Lee and Carter (1992) の対数双線形モデルを嚆矢として、コホート項を加えた拡張 (Renshaw and Haberman 2006)、高齢死亡率に特化した CBD モデル (Cairns, Blake and Dowd 2006)、P-スプラインによ

る平滑化・外挿 (Currie, Durban and Eilers 2004) などが展開され、将来死亡率を確率分布として与える。第二は実務スケールの系譜であり、Scale AA / Scale BB / MP 系列 (米国) や CMI モデル (英国) のように、解釈可能な少数パラメータ (長期改善率・収束期間) を持つ決定論的な改善率テーブルとして提供され、評価実務にそのまま組み込める形を重視する。本研究は第二の系譜に立ち、その全死因の枠組みを死因別へ拡張するものである。両系譜の役割分担——確率論的モデルは分布を、実務スケールは決定論的シナリオを与える——は、§2.3 の規制要件が決定論的ストレスを基本とすることと呼応する (確率論的拡張は §10 の将来課題)。

APC モデル。年齢・期間・コホートの三効果分解は、疫学において Holford (1983)、Clayton and Schifflers (1987) らにより定式化され、がん罹患・死亡の記述分析を中心に厚い蓄積がある。三効果の線形従属 (age + cohort = period) に由来する識別問題と、その制約による解決もこの系譜で整理された。本研究の APC 拡張 (§3.3) は Holford の規約 (参照セル制約・線形成分の期間への統合) を踏襲する。ただし疫学系 APC 研究の主目的は過去の記述・要因帰属であり、その出力を保険実務のアサンプション形式——年齢 × 暦年の率テーブルと改善スケール、および評価システムが消費できる将来投影——へ落とし込む枠組みは提供されていない。

疾病率のプロジェクション。国際的には Global Burden of Disease (GBD) 等の大規模疫学プロジェクトが疾病別の罹患・死亡の長期推計を提供するが、これらは公衆衛生上の負荷推計を目的とし、保険負債評価に必要な粒度・形式 (年齢別率の面としての整合性、シナリオ操作可能なパラメータ化) を備えない。保険側では、罹患率 (morbidity) の改善スケール整備は死亡率に比べ大きく遅れており、日本では公的統計の制約——患者調査が 3 年周期で長期パネルが成立しない (§3.1)——がその一因である。日本の実務における標準生命表や各社の経験率テーブルは静的表であり、疾病率について公的に整備された改善スケールは存在しない。

本研究が埋めるギャップ。以上を要すると、(i) 改善スケール系の先行研究は全死因死亡率に限られ、(ii) 死因別・疾病別の APC 分析は疫学的記述にとどまって実務アサンプション形式で提供されず、(iii) いずれの系譜も、改善率出力の方向性をバックテストで事前検証した上で規制要求シナリオの生成に用いるという接続を提示していない。本研究はこの三点の交差——死因別への Scale BB 拡張 (新規性 A)、実務互換形式での出力、方向性検証を根拠とするシナリオ生成器としての利用 (§6 – §7)——を埋める。

2.3 経済価値ベース規制が要求するシナリオ構造 (ICS / IFRS 17 / Solvency II)

規制環境の転換。保険負債・資本の評価枠組みは、ロックイン前提の静的評価から経済価値ベースへの転換期にある。EU では Solvency II が 2016 年に適用され、国際会計基準では IFRS 17 が 2023 年に発効した。国際資本基準 ICS は IAIS が 2024 年 12 月に採択し、日本では経済価値ベースのソルベンシー規制 (ESR) が 2025 年度から適用開始となった。本論文の執筆時点はまさに ICS 発効・ESR 適用年度にあたる (§1)。

これらの枠組みに共通するのは、負債・資本の計算が「単一のベストエスティメート点予測」ではなく「ベースシナリオ + 規定されたストレスシナリオ群」で構成される点である。要求されるシナリオは概ね次の三つの型に整理できる。

- ・ レベルショック: 率水準の即時・一律の変化 (死亡率の一律引上げ・引下げ等)
- ・ トレンドショック: 将来の改善率 (悪化率) トレンドの変更——率の時間構造そのものへの介入
- ・ カタストロフィショック: 特定の 1 年のみに載る一時的な超過 (パンデミック等)

これに感応度開示 (IFRS 17: 主要な保険リスク仮定を合理的な範囲で動かした場合の負債変化の開示) と、ORSA・中長期ストレステスト (記述的シナリオの計量翻訳) が加わる。具体的な計算と、そこで必要となる率シナリオの入力を下表に整理する。

計算	必要となる率シナリオの入力
BEL(最良推計負債)	ベースシナリオの将来率 $m(x, y)$
リスク調整 (IFRS 17)・リスクマージン	率を不利方向へストレステした将来率
ICS 保険リスクの資本賦課	レベルショックとトレンドショックを適用した将来率
カタストロフィリスク	特定年のみ超過ショックを載せた将来率
感応度開示 (IFRS 17)	単一の仮定だけを動かした将来率と、その負債変化
ORSA・中長期ストレス	公衆衛生悪化・医療進歩停滞等の記述シナリオを翻訳した将来率

シナリオ間の内的整合性。上表の各計算は独立の予測問題ではなく、同一のベースを起点とするシナリオ群の生成問題である。したがって次の性質が要求される。

1. 全シナリオで同一の年齢曲線形状 (率曲面 (rate surface) の平滑性) が維持されること
2. 年齢間の相対関係を保ったまま、率水準・トレンドだけが動くこと
3. 短期と長期に別々のショックを入れられること (例: 5 年間だけトレンドショック、以降は通常)
4. 同じ計算フローで多数のシナリオを走らせても結果が相互比較可能であること

これらが崩れると、ベースとストレスの差分が「ストレスそのものの効果」と「モデルのキャリブレーション誤差」の混合になり、規制資本計算や開示の根拠として使えない。とりわけ、モデルが出力するトレンドの符号 (改善か悪化か) がそもそも外れているならば、トレンドショックを載せる操作自体が意味を失う。すなわち、改善率の方向性が事前に検証されていることは、シナリオ生成器の基礎条件である (§6 で計測し、§7 で論じる)。

現行実務の空白。疾病発生率 (および死因別死亡率) のアサンプション実務は、静的な予定率表に一律の安全割増係数を乗じる方式が主流である。この方式はレベルショックは表現できるが、トレンドショック—改善率という時間構造を持つ変更—を陽に表現できない。経済リスク軸には ESG(経済シナリオジェネレーター) による体系的なシナリオ供給が整備されているのに対し、疾病リスク軸には対応するシナリオ生成の仕組みが存在しないのが現状である (この対比は §7 で詳述する)。

本章の含意。以上の要件構造を先に確認しておくと、本研究の検証は二つの軸で読むべきことが分かる。第一の軸は「点予測が当たるか」であり、§5 で報告するとおり、この軸において本フレームワークは単純ベースラインに一貫して劣後する。第二の軸は「上表のシナリオ構造を内的整合的に生成できるか」であり、規制が中心的に要求しているのはこちらである。第一の軸での消極的結果を、第二の軸での評価へと問いを立て直す過程が、§5 から §6 – §7 にかけての本論文の物語構造をなす。

本章で整理した規制要件は、§5 の点予測結果を評価する際の座標軸となり、§7 において本フレームワークの出力 (方向性が検証された改善率 $i^*(x, y)$ の陽出力) と一対一に接続される。次章 §3 では、検証に用いるデータと拡張アルゴリズムを定義する。

§3 データと手法 (Data and Methodology)

本章では、Scale BB を全死因死亡率から死因別（疾病別）死亡率へ拡張した本フレームワークの検証に用いたデータ (§3.1)、拡張アルゴリズムの数理 (§3.2)、世代効果を分離する APC 拡張 (§3.3)、および比較対象のベースライン手法と評価指標 (§3.4) を述べる。本章の目的は、後続の点予測精度検証 (§5) と方向性的中率の発見 (§6) を再現可能にすることであり、記法はすべてここで定義する。

記法について: 数学記号は先行研究である SOA (2012) *Mortality Improvement Scale BB Report* を踏襲する。すなわち年齢を x 、暦年を y 、長期改善率を L 、ブレンド終了（収束）年を P 、対数線形回帰の傾きを s とし、原論文 §7.4 の連続区分線形ブレンド関数 $h(y)$ を用いる。

3.1 データと対象疾病

3.1.1 入力データ

検証の入力は、厚生労働省「人口動態統計」の死因年次推移分類 5-15 表（死因 × 性 × 5 歳階級 × 年次）から得た、総人口 10 万対の死因別粗死亡率 $m(x, y)$ である。ここで x は年齢階級、 y は暦年を表す。

項目	内容
ソース	人口動態統計 5-15 表（死因年次推移分類 × 性 × 5 歳階級 × 年次）
期間	1950 – 2024 年（1950 – 2010 は 5 年刻み、2013 – 2024 は年次）
単位	人口 10 万対の粗死亡率
対象疾病	8 疾病（下表）
性別	total / male / female の 3 区分
年齢	0 – 4 歳 ~ 100+ の 21 区分（検証は 20 – 89 歳の 14 区分を使用）

5-15 表は、5 歳階級 × 年次が長期に揃う死因系時系列である。観測年が不等間隔（前半 5 年刻み、後半年次）である点は、§3.2 の年率換算ロジックで対応する（式 (3.3)）。人口動態統計は利用規約に基づき商用利用可能なデータである。

図 3.1: 入力パネルの概観 — 死因別死亡率 $m(x, y)$ の 1950 – 2024 年推移（sex = total、左: 40 – 44 歳、右: 75 – 79 歳、対数目盛）。マーカーは観測点であり、前半（1950 – 2010）が 5 年刻み・後半（2013 – 2024）が年次という不等間隔構造が読み取れる。疾病により水準（2 桁超の開き）と長期トレンドの形状（単調低下する *cerebrovascular*、増加後に反転する *cancer* 等）が大きく異なる。（生成スクリプト: `reproduction/backtest/make_paper_figures.py`）

3.1.2 対象疾病マッピング

保険対象疾病の定義（`disease_estat_mapping.csv`）のうち、5-15 表で年齢別時系列が取得できる 8 疾病をパネル化した。

Input panel: cause-specific mortality rates 1950-2024 (vital statistics table 5-15, sex=total)




図1 入力パネルの概観 — 8 疾病の死因別死亡率の推移 (sex=total、年齢 40 – 44 / 75 – 79、対数目盛)

disease_id	5-15 死因コード	ラベル	備考
cancer	Hi022017	悪性新生物〈腫瘍〉	疾病発生率に対しては死亡率代理
diabetes	Hi03	糖尿病	同上
hypertensive	Hi042017	高血圧性疾患	同上
heart_disease	Hi05	心疾患（高血圧性を除く）	同上
cerebrovascular	Hi06	脳血管疾患	同上
liver	Hi11	肝疾患	同上
kidney	Hi12	腎不全	5-15 に糸球体疾患等がなく腎不全のみ
total	Hi00	総数	全死因合計

虚血性心疾患 (heart_ischemic) は 5-15 の死因年次推移分類に存在しないため除外した。パネルの形状は 8 疾病 × 3 性別 × 25 年 × 21 年齢区分 = 12,600 行である。

3.1.3 データの二重の位置づけ —代理と対象

本研究で用いる死因別死亡率は、対象商品によって二重の位置づけを持つ。この区別は、本フレームワークの実務対象 (§7・§8) と限界 (§10) を規定する中核的な前提である。

1. 医療保険の疾病発生率に対しては「方法論検証の代理 (proxy)」である。罹患給付を伴う医療保険では、本来必要な仮定は疾病の発生率である。しかし前述のとおり日本の公開統計には「疾病別 × 年齢 × 年」の長期発生率パネルが存在しないため、発生率と共通の年齢・世代構造を持つと考えられる死因別死亡率を代理として用い、Scale BB 拡張の方法論そのものを検証する。代理である以上、致命率（罹患後死亡率）の経年変動に由来する水準差は本検証では分離できず、この留保は §10 に明記する。
2. 特定疾病死亡保障に対しては「対象そのもの (direct assumption)」である。三大疾病死亡保障・がん死亡保険・死因別の疾病死亡特約など、死因別死亡を給付事由とする商品では、死因別死亡率は代理ではなく給付現価計算のアサンプションそのものである。これらの商品に対して本フレームワークは直接適用する。

注: 本研究のデータは日本総人口あたりの死因別死亡率であり、罹患後死亡率（致命率＝死因別死亡数 ÷ 罹患数）ではない。致命率は分母に実測罹患率を要するため本研究の範囲外であり、「罹患後の予後を予測する」ことは扱わない (§10 参照)。

3.2 Scale BB 拡張アルゴリズム

Scale BB は SOA (2012) *Mortality Improvement Scale BB* を疾病別死亡率へ拡張したもので、Phase 1 (観測平滑化と改善率抽出) と Phase 2 (長期率ブレンドと将来投影) の 2 段からなる。実装は `_scalebb_core/model.py` の純粋関数群 (`fit_scale_bb` / `project_scale_bb`) に基づく。

3.2.1 Phase 1 — 2 次元平滑化と改善率抽出

観測粗率 $m(x, y)$ を対数変換し $z(x, y) = \log m(x, y)$ とおく。0 以下および欠測のセルは重み 0 として扱う。

対数率行列 $Z = (z_{x,y})$ に対し、2 次元 Whittaker-Henderson 罰則平滑化を適用する。これは SOA 原論文の P-spline 平滑化 (tensor-product B-spline + 差分罰則) と等価であり、次の目的関数を最小化する平滑化行列 $\hat{Z}$ を求める。

$$J(\hat{Z}) = \sum_{x,y} w_{x,y} (z_{x,y} - \hat{z}_{x,y})^2 + \lambda_{\text{age}} \|D_{\text{age}}^{(d)} \hat{Z}\|_F^2 + \lambda_{\text{year}} \|\hat{Z} (D_{\text{year}}^{(d)})^\top\|_F^2 \quad (3.1)$$

ここで、

- $w_{x,y}$ は観測重み (欠測・非正值セルは 0)、
- $D_{\bullet}^{(d)}$ は d 階差分行列 (既定 $d = 2$)、
- $\lambda_{\text{age}}, \lambda_{\text{year}}$ は年齢方向・暦年方向の平滑化強度、
- $\|\cdot\|_F$ は Frobenius ノルムである。

$\text{vec}(\hat{Z})$ を列優先 (Fortran order) で整列すると、式 (3.1) の停留条件は疎な線形方程式に帰着する。 $P_{\text{age}} = I_{n_{\text{year}}} \otimes (D_{\text{age}}^{(d)\top} D_{\text{age}}^{(d)})$ 、 $P_{\text{year}} = (D_{\text{year}}^{(d)\top} D_{\text{year}}^{(d)}) \otimes I_{n_{\text{age}}}$ 、 $W = \text{diag}(\text{vec}(w))$ とおくと、

$$(W + \lambda_{\text{age}} P_{\text{age}} + \lambda_{\text{year}} P_{\text{year}}) \text{vec}(\hat{Z}) = W \text{vec}(Z) \quad (3.2)$$

を疎行列ソルバで解く。年齢・暦年の粗いグリッド (最大でも 80×80 程度) では瞬時に収束する。平滑化後の率は $\tilde{m}(x, y) = \exp(\hat{z}(x, y))$ で復元する。図 3.2 に、実データ (心疾患、sex = total) に対する平滑化前後の比較を示す。

図 3.2: 2 次元 Whittaker-Henderson 平滑化 (式 3.1–3.2、 $\lambda_{\text{age}} = \lambda_{\text{year}} = 40$) の前後比較 (心疾患、sex = total、観測 ≤ 2022 、対数目盛)。マーカーが観測粗率 $m(x, y)$ 、実線が平滑化率 $\tilde{m}(x, y)$ 。左は暦年方向の断面 (代表 3 年齢) で、年次データ特有の短期変動が均されつつ長期トレンドが保存されている。右は年齢方向の断面 (代表 3 暦年) で、対数目盛上ではほぼ線形な年齢勾配が滑らかに復元されている。平滑化は年齢・暦年の両方向に同時に働くため、断面ごとの単変量平滑化では得られない整合性を持つ。(生成スクリプト: `reproduction/backtest/make_paper_figures.py`)




図2 平滑化前後の比較 — 心疾患 total の観測率と 2 次元 Whittaker-Henderson 平滑化率（左: 暦年方向断面、右: 年齢方向断面）

なお左パネルの 75 – 79 歳では、1960 – 1990 年頃の観測の山を平滑化率がやや下回る。これは既定の平滑化強度 ($\lambda = 40$) が局所水準への追従よりも長期トレンドの抽出を優先するためであり、意図された挙動である（設定は全疾病共通、§3.2.3）。

続いて、平滑化率から年率ベースの観測改善率 $i(x, y)$ を抽出する。原論文 §3.1 の BFLL (best-fit log-linear) が傾き s から年率改善 $1 - e^s$ を得るのと同じ思想で、観測年が不等間隔でも隣接 2 時点間の幾何平均改善率に換算するため、年ギャップ $\Delta y_k = y_k - y_{k-1}$ を用いて

$$i(x, y_k) = 1 - \left(\frac{\tilde{m}(x, y_k)}{\tilde{m}(x, y_{k-1})} \right)^{1/\Delta y_k} \quad (3.3)$$

と定義する。 $i > 0$ は率の低下（改善）、 $i < 0$ は率の上昇（悪化）を表す。この改善率の符号の安定性が、後述 §6 の方向性的中率の対象であり、§7 のシナリオ生成へつながる。

3.2.2 Phase 2 — 長期率ブレンドと将来投影

Phase 2 では、観測終端 y_{obs} での平滑化改善率 $i(x, y_{\text{obs}})$ を、長期想定改善率 L （既定 1%）へ収束年 P （既定 2035）に向けて線形にブレンドする。高齢域では改善が鈍化・消失する実態を反映するため、年齢別テーパー係数 $\tau(x)$ を導入し、年齢別長期率を $L_{\text{age}}(x) = L \cdot \tau(x)$ とおく。テーパー係数は、テーパー開始年齢 a_0 （既定 90）・終了年齢 a_1 （既定 120）を用いて

$$\tau(x) = \begin{cases} 1 & x \leq a_0 \\ 1 - \frac{x - a_0}{a_1 - a_0} & a_0 < x < a_1 \\ 0 & x \geq a_1 \end{cases} \quad (3.4)$$

と定義する（原論文 §5.2 の「90 歳まで長期率、120 歳で 0% へ線形逓減」に対応）。

観測終端から長期率への線形移行の重みは、原論文 §7.4 の連続区分線形ブレンド関数 $h(y)$ を踏襲する。原論文は固定開始年（2005）から P にかけて $1 \rightarrow L$ へ線形に推移する乗法係数として $h(y)$ を定義するが、本研

究はこれを (i) 開始年を観測終端 y_{obs} に一般化（可変 cutoff・死因別への拡張のため）し、(ii) 率の乗法的リ
スケールではなく、観測改善率と長期率の線形補間の重みとして用いる。すなわち

$$h(y) = \begin{cases} 0 & y \leq y_{\text{obs}} \\ \alpha_y = \frac{y - y_{\text{obs}}}{P - y_{\text{obs}}} & y_{\text{obs}} < y < P \\ 1 & y \geq P \end{cases}$$

とおくと、最終改善率 $i^*(x, y)$ は次で与えられる。

$$i^*(x, y) = (1 - h(y)) i(x, y_{\text{obs}}) + h(y) L_{\text{age}}(x) \quad (3.5)$$

すなわち、実績区間 ($y \leq y_{\text{obs}}$) では観測終端の改善率 $i(x, y_{\text{obs}})$ を保ち、収束年 P に向けて長期率 $L_{\text{age}}(x)$
へ線形に移行し、 P 以降 ($y \geq P$) は $L_{\text{age}}(x)$ で平坦となる。図 3.3 に、実データ（心疾患、sex = total、
 $y_{\text{obs}} = 2022$ ）に対する $i^*(x, y)$ の実例を示す。




図 3 改善率ブレンドの実例 — 心疾患 total、cutoff 2022 の年率改善率 $i^*(x, y)$ の推移

図 3.3: 式 (3.5) のブレンドの実例（心疾患、sex = total、 $y_{\text{obs}} = 2022$ 、代表 3 年齢）。実績区間では Phase 1
で平滑化された観測改善率（COVID-19 期の改善率低下を含む）を示し、観測終端 $y_{\text{obs}} = 2022$ の値 $i(x, y_{\text{obs}})$
から収束年 $P = 2035$ （網掛け区間）にかけて長期率 $L = 1\%$ へ線形に移行、以降は平坦となる。（生成スクリ
プト: reproduction/backtest/make_paper_figures.py）

図 3.3 について 3 点補足する。第一に、2014 – 2015 年の急峻なピーク（年率 5.6～7.0%）は、2010 年代半ば
に心疾患死亡率が急速に低下した局面を平滑化曲線が捉えたものだが、観測格子が 5 年刻みから年次へ切り替
わる 2010 → 2013 年ギャップの年率換算（式 3.3）の影響も受けるため、単年の実勢としては解釈しない。第
二に、観測終端 2022 年の改善率は 60 – 64 / 75 – 79 歳で 0.2% 弱と、COVID-19 期の改善停滞を反映して歴
史的水準（1～2% 台）を大きく下回る。ブレンドはこの抑制された値を出発点とし、「直近の異常が永続する」
とも「即座に平常へ戻る」とも仮定せずに、収束年までかけて長期率へ回帰させる。第三に、40 – 44 歳では
 $i(x, 2022) \approx 1.0\%$ が偶然 L にほぼ一致するためブレンド区間がほぼ平坦であり、ブレンドが実質的に働くの
は観測終端の改善率が長期率から乖離している場合であることが読み取れる。

将来率は、基準年 y_0 の率 $m(x, y_0)$ を起点に、改善率の累積で前向きに生成する。

$$m(x, y) = m(x, y_0) \prod_{u=y_0+1}^y (1 - i^*(x, u)) \quad (3.6)$$

本フレームワークの構造的要点は、将来率が「基準年率 $\times$ 累積 $(1 - i^*)$ 」で完全に再構成される点にある。 $i^*(x, y)$ を差し替えれば即座に新しい将来率が得られるため、長期率 L や収束年 P を操作した複数シナリオを、同一の年齢曲線形状・同一の基準年率を保ったまま内的整合的に生成できる (§7)。

3.2.3 ハイパーパラメータ

Scale BB の出力は、平滑化行列 $\hat{Z}$ や改善率 $i(x, y)$ のようにデータから推定される量のほかに、推定に先立って分析者が外生的に与える設定値に依存する。本稿では後者をハイパーパラメータと呼ぶ。具体的には、平滑化の強度と滑らかさを定める $\lambda_{\text{age}}, \lambda_{\text{year}}, d$ (式 3.1)、長期改善の想定を定める L, P (式 3.5)、高齢域の改善通減を定める a_0, a_1 (式 3.4) であり、下表に既定値とともに整理する。

本検証では疾病別チューニングを行わず、経験率集計処理の既定プリセット (`config.yaml` > `scalebb_presets` > `defaults`) を全疾病に共通適用した。疾病別キャリブレーション指針は §9 で別途論じる。

記号	パラメータ	既定値
L	長期改善率 (<code>long_term_rate</code>)	0.01 (1%)
P	収束年 (<code>convergence_year</code>)	2035
λ_{age}	年齢方向平滑化 (<code>lam_row</code>)	40
λ_{year}	暦年方向平滑化 (<code>lam_col</code>)	40
d	差分階数 (<code>diff_order</code>)	2
a_0, a_1	年齢テーパー開始・終了	90, 120
y_{obs}	観測終端 (<code>last_observed_year</code>)	cutoff (§4)

設定範囲に関する注記: 上表は本章のバックテスト (点予測・方向性の検証) で用いる設定であり、再現パッケージ `reproduction/backtest/` に対応する。前向きの世代別予定率テーブル生成パイプライン (`reproduction/generational/`、詳細は `reproduction/generational/README.md`) では、若年層 (20 歳始) 向けの率の年次変動を抑えるため暦年方向を強めた `lam_col=60`、年齢範囲 `age_min=20` の `age20` プリセットを用いる。 λ_{year} 以外の中核パラメータ ($L = 0.01$, $P = 2035$, $\lambda_{\text{age}} = 40$, $d = 2$) は両者で共通である。

3.3 APC コホートペナルティ拡張

上記の Age-Period (AP) モデルはコホート効果 $\gamma(c)$ ($c = y - x$ は生年コホート) を期間効果 $\beta(y)$ に吸収するため、「特定年齢でパンデミックを経験したコホートに固有の長期的健康影響」を数学的に識別できない。これを分離するため、加法分解可能な Age-Period-Cohort (APC) モデルへ拡張する (`scale_bb_apc_model.py`)。

観測モデルは

$$\log m(x, y) = \alpha(x) + \beta(y) + \gamma(c) + \varepsilon(x, y), \quad c = y - x \quad (3.7)$$

とし、 $\alpha(x)$ を年齢効果、 $\beta(y)$ を期間効果（医療制度改革・感染症流行・COVID-19 ショック）、 $\gamma(c)$ をコホート効果（生活習慣・医療技術アクセス・若年期の疾病曝露）とする。平滑化目的関数は、式 (3.1) に対角（コホート）方向の差分罰則を追加した

$$J(\hat{Z}) = \sum_{x,y} w_{x,y} (z_{x,y} - \hat{z}_{x,y})^2 + \lambda_{\text{age}} \|D_{\text{age}}^{(d)} \hat{Z}\|_F^2 + \lambda_{\text{year}} \|\hat{Z} (D_{\text{year}}^{(d)})^\top\|_F^2 + \lambda_{\text{cohort}} \|D_{\text{cohort}}^{(d)} \text{vec}(\hat{Z})\|^2 \quad (3.8)$$

である。対角差分行列 $D_{\text{cohort}}^{(d)}$ は、 $\text{vec}(\hat{Z})$ （列優先）上で $\hat{z}_{i+2,j+2} - 2\hat{z}_{i+1,j+1} + \hat{z}_{i,j}$ の形をとる同一コホート方向の 2 階差分として構成する（ここで i, j はそれぞれ年齢・暦年の行列インデックス）。平滑化後、 α, β, γ を加重最小二乗の反復法で抽出する（`decompose_apc_additive`）。

識別可能性。APC モデルは $\text{age} + \text{cohort} = \text{period}$ の線形従属により、3 効果の絶対水準と線形トレンド成分が未識別となる。本実装は次の 2 つを併用してこれに対処する。

- 2 階差分罰則 ($d = 2$)：定数項と線形項は罰則対象外となり、罰則付きで一意に識別されるのは 2 階以上の非線形成分のみとなる。本研究の関心は「パンデミック期に特定年齢だったコホートの非線形な逸脱」であり、この非線形成分は識別可能であるため、研究仮説と整合する。
- 参照セル制約: $\alpha(x_{\min}) = \beta(y_{\min}) = 0$ を課し、定数水準の不定性を解消する (Holford 1983)。

線形成分は Holford 規約により period へ統合し、報告は相対改善率・残差形式で行う。

COVID-19 期の取扱い。パンデミック期 (2020–2022) は通常トレンド外の構造ブレイクであり、単純平滑化は長期改善率の推定を歪める。本実装は 3 モードを提供する。

モード	処理	推奨適用
<code>weight_down</code>	COVID 年の観測重みを $w \mapsto c_w \cdot w$ ($c_w \in [0, 1]$ 、既定 0.3) に減衰	長期改善が滑らかに継続する疾病 (がん)
<code>dummy</code>	COVID 年の $\beta(y)$ を非 COVID 年の線形補間値 $\beta_{\text{corr}}(y)$ に置換し、 β_{corr} で率を再構築。ショック分 $\beta(y) - \beta_{\text{corr}}(y)$ は独立に保存	COVID 期に明瞭な不規則変動を持つ疾病 (心疾患・脳血管疾患)
<code>none</code>	COVID 年も重み 1.0 (比較基準)	ベースライン

投影では、投影期間中に新たに発生する未観測コホートの $\gamma(c)$ を外挿する必要がある。既定は末尾の 1 階差分を延長する `last_drift` (Scale BB 哲学と整合)、保守的には末尾値を固定する `flat` を用いる。

3.4 ベースライン手法と評価指標

3.4.1 ベースライン 3 手法

Scale BB の有用性を相対評価するため、改善率の概念を陽に持たない/持ち方が異なる 3 つの非 Scale BB ベースラインと比較する。いずれも年齢別 (x ごと独立) に構成する。cutoff 年 (学習終端) を y_c とする。

手法	予測規則	直感
naive_last	$\hat{m}(x, y) = m(x, y_c)$	「最新値が続く」。構造上 $\hat{m}$ は y に依存しない
mean_3pts	$\hat{m}(x, y) = \frac{1}{3} \sum_{k=0}^2 m(x, y_c^{(k)})$ (直近 3 観測点の平均)	ノイズ除去・水準平均
loglin_trend	直近 15 年で $\log m(x, y) = a_x + s_x y$ を年齢別 OLS (最小二乗法) 推定し、 $\hat{m}(x, y) = \exp(a_x + s_x y)$ で外挿	古典的アクチュアリー手法。原論文 §3.1 の BFL と同型で、年率改善 $= 1 - e^{s_x}$ を暗黙に持つ

naive_last は $\hat{m}$ が cutoff 年の値の持ち越しであるため、後述の予測変化量が常に 0 となる (方向情報を持たない)。loglin_trend は年齢別の傾き s_x を通じて陽な方向情報を持つ唯一のベースラインであり、Scale BB の最も有意義な対抗馬となる (§6)。

3.4.2 評価指標

検証セル (年齢 $x \times$ 検証年 $y \times$ 疾病 $\times$ 性別) について、実績 $m_{\text{act}}(x, y)$ と予測 $\hat{m}(x, y)$ を突き合わせ、以下の指標を算出する。実績が 0 のセルは MAPE から除外する。

点予測精度指標。検証セル集合 $\mathcal{C}$ (要素数 $N = |\mathcal{C}|$) に対し、

$$\text{MAPE} = \frac{100}{N} \sum_{(x, y) \in \mathcal{C}} \frac{|\hat{m}(x, y) - m_{\text{act}}(x, y)|}{m_{\text{act}}(x, y)} \quad [\%] \quad (3.9)$$

$$\text{bias} = \frac{1}{N} \sum_{(x, y) \in \mathcal{C}} (\hat{m}(x, y) - m_{\text{act}}(x, y)) \quad [\text{per } 10^5] \quad (3.10)$$

bias が正であれば予測が過大、負であれば過小を表す。補助的に RMSE (二乗平均平方根誤差、Root Mean Square Error) と平均相対 bias ($\frac{100}{N} \sum (\hat{m} - m_{\text{act}})/m_{\text{act}}$) も併用する。

方向性的中率 (directional accuracy; 以下 DA)。本研究の中心的発見 (§6) を支える指標で、予測が「観測終端 y_c 比で率が上下どちらに動くか」をどれだけ正しく当てているかを測る。セルごとに実績変化量と予測変化量を

$$\Delta_{\text{act}}(x, y) = m_{\text{act}}(x, y) - m(x, y_c), \quad \Delta_{\text{pred}}(x, y) = \hat{m}(x, y) - m(x, y_c) \quad (3.11)$$

と定義し、実績が変化したセル集合 $\mathcal{D} = \{(x, y) : \Delta_{\text{act}}(x, y) \neq 0\}$ に限定して、符号一致率

$$\text{DA} = \frac{1}{|\mathcal{D}|} \sum_{(x,y) \in \mathcal{D}} \mathbf{1}[\text{sign } \Delta_{\text{pred}}(x, y) = \text{sign } \Delta_{\text{act}}(x, y)] \quad [\%] \quad (3.12)$$

を集計する。ここで $\mathbf{1}[\cdot]$ は指示関数である。

この定義の下では、`naive_last` は構造上 $\Delta_{\text{pred}} \equiv 0$ となり方向情報を持たない (DA は事実上 0)。これは意図した評価軸であり、DA は「モデルが方向を当てに行ったか」を問う指標である。点予測精度 (MAPE) が測る「水準の当たり」と、方向性的中率 (DA) が測る「トレンド符号の当たり」の乖離こそが、Scale BB を点予測器ではなくシナリオ生成器として再定位する (§7) 論拠の出発点となる。

本章の記法は §4 以降で共通に用いる。検証設計 (*3 cutoff*) の詳細は §4、点予測精度の結果は §5、方向性的中率の結果は §6 に示す。データの代理性に起因する限界は §10 で正面から論じる。

§4 検証設計 (Backtest Design)

本章では、§3 で定義したモデルと評価指標を用いたバックテストの設計を述べる。中心となる設計判断は、学習打ち切り年 (cutoff) を 2014 / 2021 / 2022 の 3 通りに振る「3 cutoff 設計」であり、これは COVID-19 (2020 – 2022 の構造ブレイク) をモデルに「未知の外乱」として与えるか「学習済みショック」として与えるかを切り分けるためのものである。この設計は、点予測精度の結果 (§5) と方向性的中率の発見 (§6) の双方を、学習期間依存性まで含めて読み解く土台となる。記法は §3 を踏襲し、暦年を y 、cutoff 年を y_c で表す。

4.1 検証の枠組み — fit → project → validate

各 cutoff 年 y_c について、次の手順を踏む。

1. 学習 (fit): 観測開始年 $y_0 = 1950$ から y_c までの死因別死亡率 $m(x, y)$ に、Scale BB-D (§3.2) および 3 つのベースライン (§3.4.1) を当てはめる。すべての手法が同一の学習期間を用いる (手法間の公平な比較のため)。
2. 投影 (project): 観測終端 $y_c (= y_{\text{obs}})$ を起点に、検証終端 $T = 2024$ まで将来率 $\hat{m}(x, y)$ を生成する (式 3.5 – 3.6)。
3. 検証 (validate): ホールドアウト区間 $y \in [y_c + 1, T]$ の予測を実績と突き合わせ、§3.4.2 の指標 (MAPE · bias · 方向性的中率 DA) を年齢 × 検証年のセル単位で集計する。

検証対象は 8 疾病 × 3 性別、年齢は 20 – 89 歳の 5 歳階級 14 区分である。学習期間は 5 年刻み (1950 – 2010) と年次 (2013 – y_c) が混在する不等間隔系列だが、改善率は式 (3.3) の年率換算により整合的に扱われる。

なお、Scale BB-D の収束年は $P = 2035$ (§3.2.3) で全検証区間より先にあるため、いずれの cutoff でも検証区間 $[y_c + 1, 2024]$ はブレンド区間 $y_{\text{obs}} < y < P$ に完全に含まれる。したがって検証区間の予測は、観測終端の改善率 $i(x, y_c)$ と長期率 $L_{\text{age}}(x)$ の線形ブレンド (式 3.5、 $0 < h(y) < 1$ の領域) を反映する。

4.2 3 cutoff 設計とその意図

学習打ち切りを 3 通りに振ることで、パンデミック期をモデルの学習に含めるか否かを段階的に切り替える。

cutoff y_c	学習期間	学習観測年数	検証期間	予測ホライズン	COVID-19 の 与え方
2014	1950 – 2014	15	2015 – 2024	10 年先	未知の外乱 (学習にパン デミックを含 めない)

cutoff y_c	学習期間	学習観測年数	検証期間	予測ホライズン	COVID-19 の 与え方
2021	1950 – 2021	22	2022 – 2024	3 年先	学習済み ショック（パ ンデミック期 を学習に 含む）
2022	1950 – 2022	23	2023 – 2024	2 年先	パンデミック 後を 1 年含 め、直近デー タを最大活用




図 4 3 cutoff 設計の模式図 — 各 cutoff の学習期間・検証期間と COVID-19 期の位置関係

図 4.1: 3 cutoff 設計の模式図。各行が 1 つの cutoff に対応し、青が学習期間 ($1950 - y_c$ 、図中 train window)、赤が検証期間 ($y_c + 1 - 2024$ 、図中 validation window)、網掛けが COVID-19 の構造ブレイク期 (2020 – 2022) を表す。cutoff = 2014 はブレイクを検証期間に含み (未知の外乱)、cutoff = 2021 / 2022 は学習期間に含む (学習済みショック)。(生成: reproduction/backtest/make_paper_figures.py)

3 つの cutoff の役割は次のとおりである。

- cutoff = 2014 — COVID を「未知の外乱」として与える。学習は 2014 年で打ち切れ、2015 – 2024 年の 10 年先を予測する。2020 – 2022 年の超過死亡はモデルにとって完全に未知であり、トレンド外挿型モデルが構造ブレイクにどれだけ脆弱かを最も厳しく試す設定である。検証区間が 10 年 × 14 年齢と最大のため、方向性的中率の推定が統計的に最も安定する (§4.3)。
- cutoff = 2021 — COVID を「学習済みショック」として与える。パンデミック期 (2020 – 2021) を学習に含めた上で、COVID 後の安定期 (2022 – 2024) を予測する。パンデミックの構造変化を学習に取り込むことで、点予測がどれだけ回復するか (§5 の MAPE 縮小) を測る。
- cutoff = 2022 — 直近データを最大活用する。パンデミック後の 2022 年まで学習に含め、2023 – 2024 年を予測する。学習期間を最大化した場合の点予測性能の上限を確認する。

この 3 点は連続的な rolling-origin (全逐次移動原点) ではなく、パンデミックという構造ブレイクを前後で挟むように意図的に選んだ 3 つの固定原点である。cutoff を「ブレイク直前 (2014)」「ブレイク末 (2021)」「ブレイク後 (2022)」に置くことで、同一の構造ブレイクに対するモデルの応答を、学習への織り込み度合いの関

数として切り出せる。

4.3 検証セル数と統計的含意

各 cutoff の検証セル数は、8 疾病 × 3 性別 × 14 年齢区分 × 検証年数で定まる。

$$N_{\text{cell}} = \underset{\text{疾病}}{8} \times \underset{\text{性別}}{3} \times \underset{\text{年齢区分}}{14} \times \underset{\text{検証年数}}{H}$$

cutoff	検証年数 H	検証セル数 N_{cell}
2014	10	3,360
2021	3	1,008
2022	2	672

cutoff = 2014 はセル数が最大で、疾病別・年齢別の集計値が最も安定する。一方、cutoff = 2021 / 2022 は検証年数が短くセル数が少ないため、疾病間の指標のばらつきが大きくなる点に留意が必要である (§6 で cutoff = 2021 の方向性的中率が疾病によって大きく振れるのはこのためである)。

なお、方向性的中率 DA (式 3.11 – 3.12) の評価対象は「実績変化が生じたセル」 $\mathcal{D} = \{(x, y) : \Delta_{\text{act}} \neq 0\}$ に限られるため、その有効セル数は上表の N_{cell} より小さく、cutoff・疾病ごとに異なる。各集計の有効セル数は §6 の表に明示する。

4.4 検証で測るもの (§3.4 の適用)

各 cutoff において、§3.4.2 で定義した 2 系統の指標を適用する。

- 点予測精度 (§5 で報告) : MAPE (式 3.9) と bias (式 3.10)。「予測水準がどれだけ実績に近いか」を測る。
- 方向性的中率 (§6 で報告) : DA (式 3.12)。「観測終端 y_c 比で率が上下どちらに動くかを当てられるか」を測る。

同一の 3 cutoff 設計に対して Scale BB-D と 3 ベースラインを走らせ、両系統の指標を比較することで、「点予測では劣後するが方向は当てる」という乖離 (§5 → §6 の転換) を、学習期間依存性まで含めて定量化する。

4.5 再現

本章の 3 cutoff 設計は、再現パッケージ `reproduction/backtest/` の `run_all.sh` が一括で実行する。cutoff = 2014 の結果は `output/` 直下に、cutoff = 2021 / 2022 はそれぞれ `output/cutoff_2021/`・`output/cutoff_2022/` に生成され、`compare_cutoffs.py` が 3 cutoff の横断比較表 (§5.2 – 5.3 の表・図 5.4 – 5.5 に対応) を出力する。各 cutoff の学習・検証期間は CLI 引数 `--train-cutoff / --validation-end` で明示的に指定される (§3 再現手順参照)。

本章で設定した $3\ cutoff$ 設計に基づき、次章 §5 でまず点予測精度の結果を報告する。そこで得られる「*Scale BB-D* は全 *cutoff* で *MAPE* がベースラインに劣後する」という結果は、§4.2 の設計意図に照らせば失敗ではなく、§6 の方向性的中率の発見へと問いを立て直す出発点となる。

§5 Results I — 点予測精度の検証結果 (Point-Forecast Accuracy)

本章では、§4 の 3 cutoff 設計に基づく点予測精度の結果を報告する。結論を先に述べると、Scale BB-D は全 cutoff・全セルで最良ベースラインに MAPE (式 3.9) で劣後する。当初目的 (Scale BB-D による点予測の有用性検証) の枠内では、この結果は「Scale BB-D は短期点予測には不向き」という消極的結論に帰着する。本章はこの結果を隠さず正面から報告し、あわせて COVID-19 を学習に含めるか否かで精度がどう変わるか (独立の価値を持つ副産物) を定量化する。以下の数値はすべて再現パッケージ `reproduction/backtest/output/` の再生成結果に一致する (sex = total)。

5.1 Scale BB-D 単体の点予測精度 ($y_c = 2014$)

観測を 2014 年で打ち切り、2015 – 2024 年の 10 年間で予測した場合の Scale BB-D 単体精度を示す。

疾病	MAPE [%]	bias [per 10^5]	MAPE 2015 (1 年先)	MAPE 2024 (10 年先)
cancer	22.41	+42.6	11.96	30.95
total	26.01	– 496.2	10.99	41.54
heart_disease	31.27	– 85.3	11.12	48.52
diabetes	35.59	– 3.9	10.48	55.75
kidney	40.87	– 5.1	13.46	59.39
cerebrovascular	47.14	– 59.1	22.77	64.03
liver	49.49	– 7.8	20.53	67.50
hypertensive	73.83	– 7.1	37.02	88.33

主要な観察は次の 3 点である。

1. 予測ホライズンとともに誤差が拡大する。1 年先 (2015 年) の MAPE は 10.5 – 37.0% と短期予測として実務上の許容水準にあるが、10 年先 (2024 年) では 31.0 – 88.3% まで拡大する。Scale BB-D は観測終端付近の局所水準ではなく長期トレンドを尊重する構造モデルであるため、ホライズンが延びるほど累積的にトレンド外挿の誤差が効く。
2. cancer を除く全疾病が負バイアス (予測過小) を示す。bias が負であることは予測 < 実績、すなわち Scale BB-D が改善継続を過剰に外挿し、2020 – 2022 年の COVID-19 起因の超過死亡を取り込めなかったことを意味する。トレンド外挿型モデルが構造ブレイクに脆弱であるという §4.2 の設計仮説がそのまま現れている。
3. cancer のみ正バイアス (予測過大)。これは過去の緩やかな低減トレンドを超えて実際の治療進歩が速く進み、Scale BB-D の改善幅が実績に対して控えめだったことによる。

上記 3 点は図 5.1 – 5.3 に対応する。

図 5.1: 疾病別の年次 MAPE (左) と平均相対バイアス (右) の推移 ($y_c = 2014$, sex = total, 20 – 89 歳)。全疾病で予測ホライズンとともに MAPE が単調に拡大し (観察 1)、相対バイアスは cancer を除き負方向へ深




図5 年次別 MAPE と相対バイアスの推移 (cutoff 2014、sex=total)

化する（観察 2）。(再現: reproduction/backtest/output/figures/overall_mape_bias_by_year.png)




図6 心疾患 total の率トラジェクトリ — 観測・平滑化・Scale BB-D 投影と実績 2015 – 2024 の比較

図 5.2: 心疾患 (sex = total、代表 3 年齢) の観測率・Phase 1 平滑化率・Scale BB-D 投影 ($y_c = 2014$) と実績 2015 – 2024。Scale BB-D (緑破線) は学習期の改善トレンドをそのまま外挿するため、COVID-19 期の超過死亡を含む実績 (赤 ×) を系統的に下回る — 観察 2 の負バイアスの典型例である。(再現: reproduction/backtest/output/figures/heart_disease_total_trajectory.png)




図7 悪性新生物 total の率トラジェクトリ — 観測・平滑化・Scale BB-D 投影と実績 2015 – 2024 の比較

図 5.3: 悪性新生物 (sex = total、代表 3 年齢) の同トラジェクトリ。cancer では実績の低下が Scale BB-D 投影より速く、投影が実績を上回る（観察 3 の正バイアス）。(再現: reproduction/backtest/output/figures/cancer_total_trajectory.png)

5.2 ベースライン比較 ($y_c = 2014$) – 全 24 セルで劣後

同一設定で Scale BB-D と 3 ベースライン (§3.4.1) を比較する。

疾病	scalebb	naive_last	mean_3pts	loglin_trend	最良ベースライン	最良との差 [pp]
cancer	22.41	12.78	14.92	5.86	loglin_trend	+16.55
total	26.01	8.73	12.79	5.74	loglin_trend	+20.27
heart_disease	31.27	14.91	18.29	8.28	loglin_trend	+22.99
diabetes	35.59	21.36	20.50	19.23	loglin_trend	+16.36
kidney	40.87	14.52	13.10	14.63	mean_3pts	+27.77
cerebrovascular	47.14	18.52	26.81	12.27	loglin_trend	+34.87
liver	49.49	10.44	10.17	17.51	mean_3pts	+39.32
hypertensive	73.83	39.29	30.33	35.88	mean_3pts	+43.50

Scale BB-D は 24 セル (8 疾病 × 3 性別) すべてで 3 ベースライン全てに劣後する。最良ベースラインとの差は、改善トレンドが明瞭な疾病 (cancer / total / heart_disease) で loglin_trend に +16~+23pp、トレンドが不明瞭な疾病 (liver / hypertensive) で mean_3pts に +39~+44pp である。図 5.4 はこの劣後幅を可視化している。sex = total での唯一の例外は diabetes の 2015 年単年のみで、ここだけ Scale BB-D が全ベースラインを上回る。




図 8 Scale BB-D MAPE と最良ベースライン MAPE の差 (疾病別 × cutoff 別)

図 5.4: Scale BB-D MAPE - 最良ベースライン MAPE の差 [pp] (正 = Scale BB-D が劣後、sex = total)。 $y_c = 2014$ (赤) では全疾病で +16~+44pp の劣後を示す。 $y_c = 2021/2022$ (橙・緑) では劣後幅が縮小するが符号は正のままである (§5.3)。(再現: reproduction/backtest/output/cutoff_comparison/figures/scalebb_gap_vs_best_base)

5.3 COVID-19 期を学習に含めた場合 ($y_c = 2021/2022$)

学習打ち切りを 2021 / 2022 に移し、パンデミック期を学習に含めると、Scale BB-D の MAPE は劇的に縮小する。

疾病	$y_c=2014$	$y_c=2021$	$y_c=2022$
cancer	22.41	9.20	8.87
cerebrovascular	47.14	15.07	15.52
diabetes	35.59	16.02	13.29
heart_disease	31.27	10.27	8.37
hypertensive	73.83	24.13	20.53
kidney	40.87	16.69	15.59
liver	49.49	29.17	29.52
total	26.01	9.33	7.33

8 疾病すべてで MAPE が縮小し、その幅は 6~8 倍に及ぶ（例: hypertensive 73.83 → 24.13、total 26.01 → 9.33）。同時に bias の絶対値も全疾病で縮小し、liver は $y_c=2021$ で ($-7.8 \rightarrow +0.1$ per 10^5)、hypertensive は $y_c=2022$ で ($-7.1 \rightarrow +0.4$) 符号が負から正へ転じる。これは構造ブレイクを学習に反映することの定量的価値を示しており、COVID-19 が疾病別死亡率に与えた影響の計測として、点予測の劣後とは独立の意義を持つ（図 5.5）。




図 9 学習 cutoff 別の Scale BB-D MAPE (疾病別)

図 5.5: 学習 cutoff 別の Scale BB-D MAPE (sex = total)。パンデミック期を学習に含めた $y_c = 2021$ (橙)・ $y_c = 2022$ (緑) では、 $y_c = 2014$ (赤) に対して全疾病で MAPE が大幅に縮小する。ただし予測ホライズン (10 年 vs 2 - 3 年) も同時に短くなっている点に留意 (§4.2)。(再現: reproduction/backtest/output/cutoff_comparison/figures/scalebb_cutoff_comparison.png)

ただし、MAPE の縮小は「ベースラインに迫いつく」ことを意味しない。最良ベースラインとの差 (図 5.4) は $y_c=2014$ の +16~+44pp から $y_c=2021/2022$ で +1~+24pp へ縮むが、sex = total ではどの cutoff・どの疾病でも最良ベースラインに劣後する。「少なくとも 1 つのベースラインを上回る」セル数で見ても、24 セル中それぞれ 0 / 10 / 7 セルにとどまる (全ベースラインを上回るのは $y_c=2021/2022$ で各 2 セルのみ)。学習データを増やせば Scale BB-D は naive_last や loglin_trend のいずれかと競合する水準まで来る (例: kidney は $y_c=2021$ で naive_last(19.85) と mean_3pts(17.36) を上回るが、最良の loglin_trend(15.69) には +1.00pp 及ばない) が、最良手法には届かない。

5.4 総括 — 消極的結論と次章への転換

点予測精度に関する検証結果は明快である。

- 短期 (1–3 年先) : Scale BB-D の MAPE は 10–30% で実務上の許容水準にあるが、それでもベースラインに劣後する。
- 長期 (10 年先) : MAPE は 22–74% に拡大し、劣後幅も最大化する。
- 全 cutoff・全 24 セルで Scale BB-D は最良ベースラインに MAPE で劣後する。

当初目的が「点予測の精度」であったなら、本章の結論は「Scale BB-D は短期点予測には不向きであり、直近水準を持ち越す naive_last や対数線形外挿 loglin_trend の方が高精度」という消極的なものである。これは Scale BB-D 本来の設計思想 (数十年スパンの長期改善トレンドを抽出するモデルであり、翌年の水準を最小誤差で当ての道具ではない) と整合する結果でもある。

しかし、点予測精度という単一の軸で Scale BB-D を評価することは、この構造モデルの本質的な出力——方向性が保証された改善率 $i^*(x, y)$ ——を測り損ねている可能性がある。次章 §6 では、当初目的では測っていなかった方向性的中率 DA (式 3.12) を計測する。そこで景色は一変し、本章の消極的結論は「失敗」ではなく「問いの立て直し」へと転換する。

本章で示した「点予測 MAPE でのベースラインへの一貫した劣後」は、§6 の方向性的中率の発見と対をなす。両者の乖離こそが、§7 で Scale BB-D をシナリオ生成器として再定位する論拠の核心である。

§6 Results II — 方向性的中率の発見 (The Directional Accuracy Finding)

本章では、当初の検証計画 (§4) では測っていなかった第二の評価軸——方向性的中率 DA(式 3.11 – 3.12)——を計測する。結論を先に述べると、§5 で点予測 MAPE の劣後が最も大きかった $y_c = 2014$ (10 年先予測)において、主要 6 疾病 (全死因・脳血管・心疾患・糖尿病・がん・腎不全) の方向一致率は 77.7 – 95.0% に達する。点予測で全敗した同じモデルが、トレンドの符号 (改善か悪化か) はほぼ正しく捉えていた——この乖離が、本論文の中心的発見である。以下の数値はすべて再現パッケージ `reproduction/backtest/output/directional/` の再生成結果に一致する ($\text{sex} = \text{total}$)。

6.1 $y_c = 2014$ の方向性的中率 — 主要 6 疾病で 77.7 – 95.0%

MAPE の劣後幅が最大だった $y_c = 2014$ (2015 – 2024 年の 10 年間を予測) について、疾病別の方向性的中率を示す。DA の評価対象は実績変化が生じたセルに限られるため (式 3.12)、有効セル数 n を併記する (§4.3)。

疾病	n (有効セル)	DA [%]
total	140	95.00
cerebrovascular	134	91.04
heart_disease	137	90.51
diabetes	123	80.49
cancer	138	79.71
kidney	112	77.68
liver	118	27.97
hypertensive	110	23.64

§5.1 の結果と並べると乖離の大きさが際立つ。たとえば `cerebrovascular` は MAPE 47.14% と点予測では 8 疾病中ワースト 3 位だが、方向一致率は 91.04% に達する。`total` は 10 年先の水準を平均 26% 外しながら、140 セル中 133 セルで変化の向きを正しく当てている。すなわち Scale BB-D の誤差は「向きを外す」誤差ではなく、「正しい向きに行き過ぎる (改善を過剰外挿する)」誤差である——§5.1 で観察した負バイアスの支配と整合的である。

一方、`liver`(27.97%) と `hypertensive`(23.64%) の 2 疾病は方向ごと外している。これは 2010 年代半ば以降にこれらの死亡率が上昇局面へ転じたのに対し、既定設定 ($L = +1\%$ 、改善継続) が改善方向の投影を生成し続けたためであり、§6.5 で詳しく扱う。

6.2 3 cutoff 横断 — 学習期間によらず方向を捉えるか

学習打ち切りを 3 通りに振った場合の Scale BB-D 方向性的中率を表と図 6.1 に示す。

疾病	$y_c=2014$	$y_c=2021$	$y_c=2022$
total	95.00	42.86	60.71

疾病	$y_c=2014$	$y_c=2021$	$y_c=2022$
cerebrovascular	91.04	69.23	51.85
heart_disease	90.51	50.00	52.00
diabetes	80.49	30.30	85.71
cancer	79.71	65.00	70.37
kidney	77.68	54.55	71.43
liver	27.97	45.95	52.00
hypertensive	23.64	68.97	85.00




図 10 学習 cutoff 別・疾病別の Scale BB-D 方向性的中率の棒グラフ

図 6.1: 学習 cutoff 別の Scale BB-D 方向性的中率 (sex = total)。破線はチャンスレベル (コイン投げ、50%)。 $y_c = 2014$ (赤) では改善継続 6 疾病がチャンスレベルを大きく上回る一方、liver / hypertensive は大きく下回る。 $y_c = 2021/2022$ (橙・緑) では逆に liver / hypertensive が回復する (§6.5)。(再現: reproduction/backtest/output/directional/figures/scalebb_directional_per_cutoff.png)

図 6.1 の読み方には 2 点の留意が要る。第一に、統計的に最も安定なのは $y_c = 2014$ である。有効セル数は $y_c = 2014$ で 110 - 140 に対し、 $y_c = 2021$ は 29 - 42、 $y_c = 2022$ は 20 - 28 にすぎず (§4.3)、検証期間の短い cutoff の DA は数セルの帰趨で 10pp 単位で動く。第二に、検証期間が短い場合の低下は COVID-19 直後の年次変動を反映している。たとえば total の $y_c = 2021$ (42.86%) は、2021 年の超過死亡水準を観測終端として 2022 - 2024 年の揺り戻しの向きを問う設定であり、数十年トレンドの符号を問う $y_c = 2014$ とは性格が異なる。diabetes が 30.30% ($y_c=2021$) から 85.71% ($y_c=2022$) へ振れるのも同じ短期ノイズの表れである。長期トレンドの方向性という本章の主題に対しては、検証期間 10 年・140 セルの $y_c = 2014$ の結果——改善継続疾病で 77.7 - 95.0%——が最も信頼できる推定値である。

6.3 ベースライン比較 —方向情報を持つ手法は限られる

同一の定義で 4 手法の DA を比較する。24 比較 (8 疾病 × 3 cutoff、sex = total) での Scale BB-D の勝敗は次のとおりである。

比較対象	Scale BB-D 勝	同点	負
vs naive_last	24	0	0
vs mean_3pts	15	0	9
vs loglin_trend	12	5	7

naive_last は構造上 $\Delta_{\text{pred}} \equiv 0$ であり (式 3.11)、方向情報を一切持たない ($\text{DA} = 0\%$)。§5 で MAPE 最強クラスだった手法が、方向という軸では評価の土俵にすら乗らない——これが MAPE と DA の乖離の最も端的な表れである。mean_3pts が持つ方向情報は偶発的なものである。直近 3 点平均が cutoff 年の観測値からずれた分だけ「変化」を予測するため、cutoff 年の値がたまたま下振れした疾病 (上昇局面の hypertensive で 76.36%、liver で 61.02%) では高く出るが、改善が明瞭な疾病ではほぼ系統的に外す (total で 4.29%)。トレンド構造に基づく方向情報ではない。

唯一の意味ある対抗馬は、OLS 傾きという陽な方向情報を持つ loglin_trend である。Scale BB-D は 12 勝 5 分 7 敗で正味勝ち越すが、内訳に構造がある。 $y_c = 2014$ では cerebrovascular(91.04%) と heart_disease(90.51%) で両者完全に同値、total は 95.00% 対 94.29% とほぼ同値であり、改善トレンドが明瞭な疾病では長期構造モデルと対数線形外挿が同じ符号に到達する。Scale BB-D の負けは主に cancer(3 cutoff すべてで劣後、 $y_c=2014$ で 79.71% 対 93.48%) と、検証期間が 2 年と短い $y_c = 2022$ に集中する。逆に $y_c = 2021$ では heart_disease(50.00% 対 26.19%) や total(42.86% 対 16.67%) で Scale BB-D が大きく上回る。COVID 期を含む直近 15 年の OLS が水準シフトに引きずられて方向を外す局面でも、数十年の構造から方向を決める Scale BB-D は崩れ方が緩やかである (図 6.2)。




図 11 Scale BB-D と loglin_trend の方向性的中率の直接比較 (3 cutoff 横並び)

図 6.2: Scale BB-D(緑) と loglin_trend(赤) の方向性的中率の直接比較 (sex = total、3 cutoff 横並び、破線は 50%)。左 ($y_c=2014$) では cancer を除き同等以上、中央 ($y_c=2021$) では heart_disease / total / cerebrovascular で Scale BB-D が優位、右 ($y_c=2022$) では短い検証期間のノイズの中で loglin_trend が優位のセルが増える。(再現: reproduction/backtest/output/directional/figures/scalebb_vs_loglin_directional)

6.4 乖離は何を意味するか — 構造モデルと点予測器の本質的差異

MAPE (§5) と DA (本章) の乖離は、偶然ではなくモデルの設計に由来する。naive_last / mean_3pts は「直近水準が続く」と仮定する点予測器、loglin_trend は「直近 15 年の対数線形傾きが続く」とする短期外挿器である。短期 (1–3 年) の水準は観測終端の水準と直近トレンドではほぼ決まるため、点予測ではこれらが構造的に有利になる。一方 Scale BB-D は、観測終端付近の局所水準よりも、60 年超の観測から抽出した長期トレンドと長期率 L への収束 (式 3.5) を尊重する設計であり、観測終端付近のノイズや短期ショックをあえて無視する。これが短期 MAPE で劣後する根本原因である (§5.4)。

その代償として得ているのが方向の安定性である。改善率の符号は数十年スパンの構造から決まるため、観測終端がどの局面にあっても大きく揺れない——§6.2 で見た cutoff 横断の頑健性はその表れである。すなわち Scale BB-D は「次年度の水準を最小誤差で当てる道具」ではなく、「長期トレンドの方向と強度を、方向性が検証された改善率 $i^*(x, y)$ として陽に取り出す道具」である。水準の点予測を問う限り §5 の消極的結論は覆らないが、改善率の符号と操作可能性を問う用途——複数シナリオの生成——では、この性質こそが要件になる (§2.3, §7)。

6.5 方向反転疾病の扱い —キャリブレーションの適用範囲と限界

liver / hypertensive の方向外れ (DA 23.6 – 28.0%) は、Scale BB-D の既定設定 $L = +1\%$ (改善継続) が、2010 年代半ば以降の上昇転換という事実と食い違ったケースである。実務適用上の関心は「この方向外れは修正可能か」にある。ここでは 2 つの修正経路——(i) キャリブレーション経路: 疾病別に $L \cdot P$ を再設定する、(ii) データ経路: 反転後の直近データを学習に取り込む——を切り分けて検証する。結果を表 6.1 と図 6.3 に示す。

表 6.1: 方向反転疾病の再キャリブレーション実験 (sex = total, DA [%])

設定	経路	liver	hypertensive
$y_c=2014$, 既定 ($L=+1\%$, $P=2035$)	—	27.97 ($n=118$)	23.64 ($n=110$)
$y_c=2014$, $L=0\%$ (P 据置)	キャリブレーション	27.97	23.64
$y_c=2014$, $L=0\%$, $P=2020$	キャリブレーション	33.05	30.91
$y_c=2021$, 既定	データ	45.95 ($n=37$)	68.97 ($n=29$)
$y_c=2022$, 既定	データ	52.00 ($n=25$)	85.00 ($n=20$)




図 12 方向反転疾病 (liver / hypertensive) の方向一致率 —キャリブレーション経路とデータ経路の比較

図 6.3: 方向反転疾病の方向一致率の回復 — キャリブレーション経路 (赤系: $y_c = 2014$ のまま $L \cdot P$ を再設定) とデータ経路 (橙・緑: 反転後データを学習に取り込む)。破線は 50%。(生成スクリプト: reproduction/backtest/make_calibration_recovery_figure.py)

この実験は 3 つの事実を示す。

1. 長期率の差し替えだけでは、検証期間内の方向は変わらない。 L を +1% から 0% へ引き下げても DA は不変である (-1% まで下げても同じ)。理由は式 (3.5) の構造にある。検証期間 2015–2024 は全域がブレンド区間 $y_{\text{obs}} < y < P$ に含まれ (§4.1)、そこでの改善率は観測終端改善率 $i(x, y_c)$ と L の線形内分で与えられるが、観測終端に近い年ほど $i(x, y_c)$ 側の重みが多い。 $y_c = 2014$ の $i(x, y_c)$ は学習期の改善継続を反映して正であり、さらに観測格子が 5 年刻みから年次へ切り替わる境界に観測終端が重なるため平滑化値が実勢より大きく出る (図 3.3 で注意した境界効果と同根)。短期の投影方向はこのアンカーが支配し、 L はほとんど寄与しない。
2. 収束年の前倒しを併用すると部分的に回復するが、限定的である。 $L = 0\%$ に加えて P を 2035 から 2020 へ前倒しすると、観測終端アンカーの支配が早期に解けて DA は 33.05% / 30.91% まで改善するが、なおチャンスレベルを下回る。検証期間の大半が反転前の正の改善率で投影されるためである。
3. 本格的な回復はデータ経路で起こる。反転後の観測を学習に含めた $y_c = 2021/2022$ では、キャリブレーションを一切変えない既定設定のまま、liver は 45.95 / 52.00%、hypertensive は 68.97 / 85.00% まで回復する。Phase 1 が抽出する観測改善率 $i(x, y)$ の符号自体がデータから修正されるためであり、Scale BB-D は直近トレンドが学習に反映されれば構造的に方向修正が効く。

この切り分けの実務的含意は次のとおりである。 $L \cdot P$ の疾病別キャリブレーションが支配するのは収束年以降の長期の方向であり、その効果は 10 年の検証期間では観測できない——だが保険負債評価の投影ホライズン (数十年) ではそこが支配的になるため、反転疾病に対する $L \leq 0$ への再設定は長期シナリオの整合性の必要条件である (疾病別キャリブレーション指針は §9.1)。一方、観測終端付近の短期の方向は、キャリブレーションではなく最新データでの定期的な再フィットが担う。すなわち「疾病別の長期率設定」と「定期再フィット」は代替ではなく分担の関係にある。付言すれば、この修正可能性自体が構造モデルに固有の性質である。naive_last には修正すべき方向情報がなく、loglin_trend で傾きの符号を手動反転させることは推定の前提を放棄することに等しい。改善率とその長期想定を陽なパラメータとして持つからこそ、方向の誤りを特定し、修正し、再検証できる。

最後に、この検証可能性の限界が持つ意味を明確にしておく。 L の長期効果それ自体は、収束年以降の実績が蓄積するまで直接検証できない (既定設定では 2035 年以降の実績を要する)。ただしこれは本フレームワーク固有の弱点ではなく、長期改善想定というものの一般の性質である。しかも実績を待つ間にも次の構造ブレイク——新たな感染症の流行や医療技術の転換——が混入しうる以上、「データの十分な蓄積を待って検証を完結させる」という方針は原理的に閉じない。本フレームワークの設計はその逆を行く。限られたデータでも検証可能な部分——改善率の方向性——は本章までの検証で固めた土台とし、検証の届かない長期想定は、暗黙の前提として埋め込むのではなく解釈可能な少数パラメータ ($L \cdot P$) として明示し、シナリオとして振る対象へ転換する (§7)。将来の構造ブレイクについても、事後には定期再フィットが方向を自動修正し (本節のデータ経路が COVID-19 で実証したとおり)、事前には $L \leq 0$ やカタストロフィショックといったストレスシナリオとして定量化しておくことができる。長期の不確実性を点予測で言い当てようとするのではなく、検証済みの方向性の上で不確実性を陽に扱う——この構えこそが、単一の点予測ではなくシナリオ間整合性を要求する経済価値ベース評価 (§2.3) と整合する。

§5 の「点予測は全敗」と本章の「方向は 77.7–95.0% 的中」という乖離は、*Scale BB-D* の価値が単年水準の予測ではなく、方向性が検証された改善率 $i^*(x, y)$ の陽出力にあることを示している。次章 §7 では、この性質が経済価値ベース評価 (*ICS / IFRS 17*) の要求するシナリオ生成構造 (§2.3) へ、どのように一対一に翻訳されるかを論じる。

§7 Repositioning — シナリオ生成器への再定位 (Scale BB-D as a Scenario Generator for ICS / IFRS 17)

§5 と §6 で得た「点予測 MAPE では一貫して劣後するが、改善トレンドの方向はほぼ的中する」という乖離を、§2.3 で先に整理した二つの評価軸に載せて読み直すのが本章である。第一の軸 (点予測が当たるか) での消極的結論は §5 のとおり覆らない。しかし経済価値ベース評価 (ICS / IFRS 17 / Solvency II、日本では ESR) が中心的に要求しているのは第二の軸——ベースを起点とするシナリオ群を内的整合的に生成できるか——であった。本章では、§6 の発見が経済価値評価の文脈で持つ含意を 3 点に整理し (§7.1)、規制が要求するシナリオとの実装対応 (§7.2)、ベースライン手法が同じ役割を担えない構造的理由 (§7.3)、ESG との役割分担 (§7.4)、導入負担 (§7.5)、および特定疾病死亡保障への直接適用 (§7.6) を論じる。

7.1 発見の読み替え — 3 つの構造的性質

§6 までの検証結果は、経済価値評価の文脈では次の 3 点に整理できる。

1. 方向性の安定は、シナリオ間整合の基礎条件である。§2.3 で述べたとおり、規制計算の実体は「同一のベースを起点とするシナリオ群の生成」であり、ベースとストレスの差分がストレスそのものの効果と一対一対応することを要する。モデルが出力するトレンドの符号自体が外れていれば、長期率 L を動かした差分は「ショックの効果」と「キャリブレーション誤差」の混合になり、資本計算や開示の根拠に使えない。§6 のバックテストは、この基礎条件——改善率 $i^*(x, y)$ の符号が事前検証済みであること——を主要 6 疾病について与える (方向反転疾病への対処は §6.5 の役割分担による)。
2. 改善率の陽出力は、ショックの直接実装を可能にする。式 (3.6) のとおり、将来率は基準年率と改善率経路 $i^*(x, y)$ から完全に再構成される。したがってシナリオの定義はすべて i^* への操作として書け、長期率 L ・収束年 P ・年齢テーパー $\tau(x)$ という少数の解釈可能なパラメータの差し替えがそのままシナリオ生成になる。「改善率を持たない」手法にはこの操作面が存在しない (§7.3)。
3. 2 次元平滑化は、全シナリオでの年齢曲線整合を保証する。Phase 1 の fit はシナリオ間で共有され、シナリオごとに再実行するのは Phase 2 (ブレンドと投影) のみである。ゆえに全シナリオが同一の平滑化年齢曲線と同一の基準年率を起点に持ち、シナリオ間の差分は改善率経路の違いだけに帰着する。§2.3 で挙げた 4 要件 (年齢曲線形状の維持・相対関係の保存・短期と長期の分離・多数シナリオの相互比較可能性) は、この構造から同時に満たされる。

7.2 規制シナリオへの実装対応

§2.3 の表 (必要となる率シナリオの入力) に、本フレームワークでの実装を対応させたものが表 7.1 である。規制上の例には、§8 で実際に用いる 1 柱告示 (令和 7 年金融庁告示第 74 号) の係数を含む。

表 7.1: 規制が要求するシナリオ型と本フレームワークでの実装対応

シナリオ型 / 計算	規制上の例	本フレームワークでの実装
ベースシナリオ (現在推計・BEL)	計算前提を基準日で再評価した将来率 $m(x, y)$	式 (3.6) の投影率をそのまま使用
レベルショック	ESR: 死亡率 +12.5%(告示第 56 条)、死亡率 - 20%(長寿、第 57 条)、罹患・障害の発生率 +20%(第 59・60 条)	投影率への一律乗算 (Phase 2 出力に係数を乗じる)。§8 の $ICS_C \cdot ESR_M$
トレンドショック	将来の改善率トレンドの変更 (§2.3 の型整理。ORSA・内部管理・感応度開示が主領域、§8.5)	L の差し替え → Phase 2 再投影のみ。§8 の UP50 / DN50 / ICS_T
カタストロフィショック	感染症の流行: 死亡率が即時に 1/1,000 増加 (告示第 95 条)	初年度の $i^*(x, y_0+1)$ を、 $m(x, y_0+1)$ が +0.001 となるよう書き換えて再投影
感応度開示 (IFRS 17)	主要な保険リスク仮定を合理的範囲で動かした負債変化	$L \pm 50bp \cdot P \pm 5 \text{ 年} \cdot a_0 \pm 5 \text{ 歳のグリッド実行}$
ORSA・中長期ストレス	公衆衛生悪化・医療進歩停滞等の記述シナリオの定量化	$L = 0$ または負債への再設定 ($L \leq 0$ の挙動検証は §6.5)

表 7.1 の実装列に共通するのは、いずれも同一の Phase 1 fit を共有し、ScaleBBConfig の設定差し替えによる Phase 2 再投影 (または出力への係数乗算) だけで生成される点である。Phase 1 は L に依存しないため、シナリオ追加の限界コストは Phase 2 一回分にとどまる。また APC 拡張 (§3.3) を用いれば、特定世代の追加リスクや改善加速といったコホートショックも、世代効果 $\gamma(c)$ への操作として同じ型で実装できる。

レベルショックとトレンドショックの違いは、単なる実装の違いではなく、リスクの年齢構造の違いとして現れる。§8.4 の数値例を先取りすると、規制のレベルショック (発生率 +20%) の給付現価への影響は加入年齢によらずほぼ一律 (+17~19%) だが、トレンドショック (改善率ゼロ) は 30 歳加入で +31~32%、60 歳加入で +10~11% という明瞭な年齢勾配を持つ。静的表に一律係数を乗じる現行方式では、この年齢構造を持つリスクは原理的に表現できない。

7.3 ベースライン手法が同じ役割を担えない理由

§5 で最も精度の高い点予測だったベースライン手法群は、シナリオ生成器としては構造的に機能しない。

naive_last / mean_3pts には改善率という概念がない。表現できるのは水準の乗算 (レベルショック) だけであり、トレンドショック——率の時間構造への介入——を定義する場所が存在しない。§6.3 で見たとおり方向情報も持たない (または偶発的にしか持たない) ため、「方向が検証されたベースからの乖離」というシナリオの構図自体が成立しない。

loglin_trend は OLS 傾きという陽なトレンドを持ち、§6.3 のとおり方向情報も相応に高い。しかしシナリオ生成に必要な構造を 3 つの点において欠く。第一に時間構造がない。推定に用いた観測期間 (直近 15 年) の傾きを全将来に固定するため、「短期は観測トレンドを継続し、長期は想定改善率へ収束する」という Phase 2 の時間構造 (式 3.5) や、「5 年間だけトレンドショック、以降は通常」といった §2.3 の要件 3 を表現できない。第二に年齢構造がない。年齢別に独立な OLS であるため age $\times$ period の交互作用を持たず、傾きへの一律シフトはできても「若年層は改善継続・高齢層は鈍化」のような年齢依存ショックは年齢ごとの手動設定に

なる。高齢域のテーパも持たないため外挿が発散しやすく、隣接年齢間で改善率の逆転が生じ、ショック後の率曲面が平滑性を失う——年齢間で不整合な率カーブは商品設計にも資本計算の根拠にも使えない。第三に、これらを外生的に補おうとすると(傾きの手動反転・年齢別の傾き調整)、推定手法としての前提を放棄したアドホックな表操作に戻ってしまい、§2.3の「差分がショック由来と一対一対応する」性質が失われる。

このことから、点予測器・短期外挿器の系譜は「単一の将来を当てる」ために作られており、「複数の将来を整合的に張る」ための操作面——方向性が検証された改善率の陽出力——を持たないと言える。この操作面の有無こそが、§5のMAPE比較では見えなかった本質的な差である。

7.4 ESG との対比 —疾病リスク軸の決定論的シナリオ生成器

「シナリオ生成器」という語は、保険実務ではESG(経済シナリオジェネレーター)を想起させるため、役割の違いを明確にしておく。ESGは金利・株式等の経済リスク軸について、確率測度の下で数千本の確率論的パスを生成する装置であり、市場整合的評価やオプション・保証の時間価値計算を担う。これに対して本フレームワークが担うのは、疾病リスク軸——医療保険では疾病発生率(代理)、特定疾病死亡保障では死因別死亡率(直接)——の決定論的シナリオ生成である。ICS / ESRの保険リスクが要求するのは確率パスではなく所定の決定論的ストレスであり(§2.3、§8.1)、経済軸にはESGという体系的な生成装置が既に整備されている一方、疾病リスク軸の対応物は存在せず、静的な予定率表に一律係数を乗じる方式が実務の現状である。本提案はこの空白——トレンドショックを表現できないアサンプション実務——を埋める、経済軸のESGと対をなす装置の新設にあたる。

両者は競合せず、プロジェクションエンジンで合流する分担関係にある。ESGが割引率・市場シナリオを供給し、本フレームワークがシナリオ別の率テーブルを供給し、負債評価モデルが両者を消費する。§8のデモはまさにこの構図——ESR準拠の割引率カーブ × シナリオ別クレーム率テーブル——で計算されている。なお、改善率の残差分布に基づく確率論的拡張(たとえば L の分布からのブートストラップ生成)は本フレームワークの自然な将来拡張だが、本論文の範囲外である(§10)。

7.5 導入負担への予告

「生成器の新設」という表現は大がかりな基盤投資を想起させるが、既存ワークフローへの導入負担は低い。生成器はプロジェクションエンジンの上流に位置し、その出力は既存の評価実務が既に消費している形式の率テーブルそのものであり、現行のストレス用テーブル作成工程(静的表 × 一律係数)の追加ではなく置換として機能する。導入負担の体系的な分析と段階的導入パスは§9.2で論じる。

7.6 特定疾病死亡保障への直接適用 —二層の適用可能性

最後に、本フレームワークの適用対象を§3.1.3の二重の位置づけに沿って明確にする。医療保険の罹患給付に対しては、死因別死亡率は発生率の代理であり、§6の方向性検証は「方法論の検証」として読まれる——発生率そのものである検証は今後の課題である(§10)。一方、死因別死亡を給付事由とする商品——三大疾病死亡保障、がん死亡保険、死因別の疾病死亡特約——に対しては、本研究が検証した死因別死亡率がアサンプションそのものであり、代理の留保なくシナリオ生成器を直接適用できる。 L の操作によるトレンドショック、告示係数によるレベルショックは、これらの商品の給付現価の感応度にそのまま反映される(§8では同一の率テーブルが、読み方に応じて罹患ストレス(ESR_M)と死亡ストレス(ICS_C のレベル部分)のいずれの規制対応も持つことを示す)。

すなわち本フレームワークの実務上の適用対象は二層をなす。医療保険（発生率商品）では検証済み方法論の代理適用として、特定疾病死亡保障では直接適用として働き、後者では §6 の方向性検証がそのまま当該アサンプションの検証になる。なお、罹患後死亡率（致命率）の予測はいずれの層でも主張しない (§10)。

本章で、§6 の発見は「方向性が検証された改善率の陽出力を持つ唯一の手法が、規制要求シナリオを設定差し替えだけで整合的に生成できる」という再定位として読み替えられた。次章 §8 では、この生成器を *ESR* の実装仕様（割引率カーブ・告示ストレス係数）の上に載せ、*BEL* 感応度という具体的な数字で「*So what*」に答える。

§8 財務インパクトのデモ (Financial Impact Demonstration)

本章では、§7 で示した「シナリオ生成器としての再定位」の実務的意義を、簡易プロジェクションモデル上の BEL(給付現価) 感応度として定量的に示す。目的は精緻な負債評価ではなく、長期改善率 L の操作が給付現価に与える影響の方向と桁を、経済価値ベースの評価枠組みにそのまま適用できる形で提示することである。計算は 2026 年 3 月 31 日に日本で適用が開始された経済価値ベースのソルベンシー規制 (ESR) の実装仕様に、簡易モデルの範囲で可能な限り準拠させた (§8.1)。

8.1 デモの設計 — 簡易モデルと ESR 実装仕様への準拠

計算主体は決定論的・年次ステップの簡易プロジェクションモデルである。発行年 2026 年・加入年齢 x_0 のモデルポイントに対し、給付現価を

$$\text{BEL}(x_0) = \sum_{t=0}^{T-1} P(t) S(t) q_{\text{dis}}(x_0 + t, 2026 + t) \text{SA} \quad (8.1)$$

$$S(0) = 1, \quad S(t+1) = S(t) (1 - q_{\text{dis}} - q_{\text{death}} - q_{\text{lapse}}) \quad (8.2)$$

で評価する。ここで q_{dis} は 3 疾病 (がん・心疾患・脳血管疾患) のシナリオ別クレーム率の合計、 q_{death} は全死因の投影率 (ベースシナリオで固定・全シナリオ共通 — 感応度を疾病率の変化のみに帰着させるため)、 q_{lapse} は解約率、 $P(t)$ は年限 t の割引係数、SA は保険金額である。各年齢・各年の率は、§3 のフレームワークが出力する率曲面 $m(x, y)$ の世代対角線 $m(x_0 + t, 2026 + t)$ から取得する。

ESR の実装仕様への準拠は次の 4 点である。

1. BEL の位置づけ。式 (8.1) は、ESR における保険負債のうち「現在推計」(計算前提を基準日で再評価した将来キャッシュフローの現在価値) に対応する。生命保険リスク内のサブリスク統合と MOCE(不確実性マージン、Margin Over Current Estimate) は §8.5 で簡易計算する。リスクカテゴリー間 (市場・信用・オペリスク等との) 統合、適格資本、ESR 比率そのものは、資産側を持たない本デモの範囲外とする。
2. 割引率。割引係数 $P(t)$ には、金融庁が公表する「イールド・カーブ作成ツール」(2026 年 3 月末基準) のパラメータ — 円金利の観測最終年限 30 年、終局金利 (UFR: Ultimate Forward Rate) 3.8%、収束年限 60 年、および年限別ゼロクーポン無リスク金利 (観測 13 年限) — から、Smith-Wilson 補外により再現した無リスク金利カーブを用いる (観測年限は完全再現、収束年限における瞬間フォワードは UFR $\pm 1\text{bp}$ 以内)。一般バケット等のスプレッド調整は適用しない。
3. 感応度の測定方式。ESR の生命保険リスクは「経済価値ベースの資産・負債に所定のストレスを与えた場合の純資産の変動額を計測する方式」(ストレス方式) で計算される。本デモの感応度 ΔBEL はこれと同型であり、資産側を不変とすればストレス方式の純資産減少額にそのまま対応する。
4. 規制ストレス係数の採用。シナリオの一部 (§8.2 の ESR_M と ICS_C のレベル部分) には、1 柱告示 (令和 7 年金融庁告示第 74 号) が定めるストレス係数そのもの — 罹患・障害リスクの発生率 +20%(第 59・60 条: 健康事象発現時の一時金を提供する商品区分・保険期間 5 年超・日本)、死亡リスクの死亡率 +12.5%(第 56 条: 日本) — を用いる。

一方、簡易モデルとしての限界も明示する。キャッシュフローは給付のみであり保険料・事業費は含まない（給付現価としての評価）。脱退は独立近似で処理し、全死因死亡率には 3 疾病由来の死亡が含まれる（全シナリオ共通のため感応度への影響は二次的）。また §3.1.3 のとおり、率は死因別死亡率であり、医療保険の発生率に対しては代理である。保険会社で導入実績のある実務プロジェクションモデル上での再実行は今後の検証課題である (§10)。

8.2 シナリオとモデルポイント

シナリオは次の 6 本である。いずれも §3.2 の同一の fit(Phase 1) を共有し、UP50/DN50/ICS_T は設定 L の差し替えによる Phase 2 再投影のみ、ICS_C・ESR_M は率への一律乗算のみで生成される。

SCN_CD	内容	生成方法	規制上の位置づけ
BASE	ベース ($L = 1.0\%$)	既定設定	現在推計のベースシナリオ
UP50	改善加速 ($L = 1.5\%$)	L 差し替え	IFRS 17 感応度 開示 +50bp
DN50	改善減速 ($L = 0.5\%$)	L 差し替え	IFRS 17 感応度開示 - 50bp
ICS_T	改善停止 ($L = 0\%$)	L 差し替え	トレンドショック (改善率ゼロ)
ICS_C	改善停止 + レベル	$ICS_T \times 1.125$	トレンド + 死亡レベル ショックの合成 (+12.5% は告示第 56 条の死亡リス ク係数と同水準)
ESR_M	罹患ストレス	$BASE \times 1.20$	告示第 59・60 条罹患・ 障害リスク (一時金区 分・長期・日本: 発生率 +20%)

モデルポイントは、三大疾病一時金 100 万円 (初回罹患時)・90 歳満了の保障を、加入年齢 30/40/50/60 歳 × 男女の 8 点 (MP01 – MP04 男性、MP05 – MP08 女性) に置いたものである。解約率は年 3% 固定、死亡脱退は全死因投影率で、いずれも全シナリオ共通とする。

シナリオ表は、§3.1.3 の二層の適用可能性と次のように対応する。同一の率テーブルが、(i) 医療保険の疾病発生率の代理として読む場合は罹患・障害リスク (ESR_M) の対象となり、(ii) 特定疾病死亡保障のアサンプションとして読む場合は死亡リスク (+12.5%、ICS_C のレベル部分と同水準) の対象となる。すなわち本デモの一表は、二層のどちらの読み方でも規制ストレスとの対応を持つ。

8.3 結果 — BEL 感応度の一表

表 8.1 に、モデルポイント別の BASE シナリオ BEL(保険金額 100 万円あたり、円) と、各シナリオの BASE 比変化率を示す。

表 8.1: モデルポイント別 BEL 感応度 (BASE 比変化率 %)

MP	加入年 齢・性別	BASE BEL(円)	UP50	DN50	ICS_T	ICS_C	ESR_M
MP01	30 男	14,420	- 12.6	+14.5	+31.0	+45.3	+18.3
MP02	40 男	29,094	- 9.5	+10.5	+22.2	+35.5	+18.1
MP03	50 男	56,215	- 6.7	+7.3	+15.1	+27.5	+17.7
MP04	60 男	100,454	- 4.4	+4.6	+9.5	+21.1	+17.2
MP05	30 女	9,681	- 12.5	+14.7	+31.8	+47.1	+19.1
MP06	40 女	19,221	- 9.7	+10.9	+23.3	+37.6	+18.9
MP07	50 女	36,139	- 7.2	+7.9	+16.5	+29.9	+18.7
MP08	60 女	62,764	- 5.0	+5.3	+11.0	+23.7	+18.4
合計	—	327,988	- 6.6	+7.2	+15.0	+27.7	+18.0




図 13 モデルポイント別・シナリオ別の BEL 感応度 (BASE 比変化率 %, 加入年齢順)

図 8.1: モデルポイント別・シナリオ別の BEL 感応度 (BASE 比変化率 %)。横軸はモデルポイント (加入年齢・性別、加入年齢順)、系列は UP50 / DN50 / ICS_T / ICS_C / ESR_M の 5 シナリオ。(生成スクリプト: ScaleBB/Research/scripts/bel_demo/aggregate_bel_results.py)

結果は 3 点に要約できる。第一に、全モデルポイントで L に対する単調性 ($UP50 < BASE < DN50 < ICS_T < ICS_C$) が成立し、 L の操作が給付現価に整合的に翻訳されている。第二に、感応度には明瞭な年齢勾配があり、加入年齢が若いほど大きい (ICS_T で 30 歳 +31~32% に対し 60 歳 +10~11%)。改善トレンドの変化は残存期間にわたって複利的に蓄積するため、長期の契約ほど影響が大きいという直感と整合する。第三に、女性は BASE の給付現価水準が男性より低い一方、変化率でみた感応度は全シナリオで男性をやや上回る。

8.4 考察 —トレンドショックとレベルショックの対比

表 8.1 で最も示唆的なのは、ESR_M と ICS_T の対比である。告示のストレス方式による罹患・障害リスク (ESR_M: 発生率 +20% の一律レベルショック) の影響は、加入年齢によらずほぼ一定 (+17.2~+19.1%) である。これは静的な率テーブルに一律係数を乗じるという現行実務の構造 (§2.3) がもたらす当然の帰結である。一方、トレンドショック (ICS_T: 改善率ゼロ) の影響は +9.5% から +31.8% までの年齢勾配を持ち、合

計では規制レベルショックに近い水準 (+15.0% 対 +18.0%) でありながら、30 歳では規制レベルショックの約 1.7 倍、60 歳では 6 割弱となる。

この対比は 2 つの実務的含意を持つ。第一に、改善トレンドの不確実性は若年・長期の契約に集中するため、一律のレベル係数だけでリスクを把握すると、ポートフォリオの年齢構成によってはトレンドリスクを系統的に過小評価 (または過大評価) しまう。第二に、この時間構造を持つショックは、改善率 $i^*(x, y)$ を陽に出力する枠組みでなければ生成できない (§7.3 のベースライン手法の限界)。本フレームワークでは L の差し替えのみで生成でき、しかも §6 で示したとおりその方向性はバックテストで事前検証されている。規制の第 1 の柱の標準的手法がレベルショックを基本とする中で、ORSA・感応度開示・内部管理 (第 2 の柱) においてトレンドシナリオを補完的に走らせる用途に、本フレームワークは追加の改修なくそのまま適用できる。

なお、ICS_C のレベル部分 ($\times 1.125$) は告示第 56 条の死亡リスク係数 (日本 +12.5%) と同水準であり、特定疾病死亡保障 (新規性 B・直接適用の層) に対しては、ICS_C が「トレンドショックと規制死亡ストレスの合成」という規制対応上の解釈をそのまま持つ。医療保険 (発生率への代理適用の層) に対しては ESR_M が対応する。二層のいずれの読み方でも、本デモの感応度は規制ストレスの語彙で解釈可能である。

導入負担の議論は §9.2 で行う。

8.5 拡張 — 生命保険リスク所要資本と保険負債の簡易計算

前節までの感応度は個別ストレスの ΔBEL であった。本節では 1 柱告示の標準的手法に一段踏み込み、本ポートフォリオの生命保険リスクのサブリスク 5 種を告示のストレス係数 (いずれも日本の地理的区分) で計算し、相関統合 (第 81 条) と MOCE (第 29 条) まで進めた結果を示す。

表 8.2: 生命保険リスク所要資本と保険負債の簡易計算 (8 モデルポイント合計、円)

項目	額 (円)	適用した告示の規定
サブリスク: 死亡	0	第 56 条 (死亡率 +12.5%。本商品では死亡は脱退側のため純資産減少に該当せず 0)
サブリスク: 長寿	11,698	第 57 条 (死亡率 - 20% → 生存者増加により給付現価増)
サブリスク: 罹患・障害	58,917	第 59・60 条 (発生率 +20%。表 8.1 の ESR_M の ΔBEL と定義上一致)
サブリスク: 解約・失効	50,096	第 61~63 条 (水準トレンド $\pm 25\%$ と大量解約 30% の大きい方。本商品は解約率低下側が拘束)
サブリスク: 経費	0	第 64 条 (本デモは経費キャッシュフローを持たない)
生命保険リスク (相関統合後)	80,067	第 81 条の相関行列 (単純合算 120,711 に対し分散効果 - 34%)
現在推計 (BASE BEL 合計)	327,988	式 (8.1)

項目	額 (円)	適用した告示の規定
MOCE	32,286	第 29・30 条 (資本コスト率 3%、推計所要資本のランオフ・パターン近似。現在推計比 9.8%)
保険負債 (現在推計 + MOCE)	360,273	—

この計算は 3 点の含意を持つ。第一に、本商品 (罹患給付) の生命保険リスクの最大の構成要素は罹患・障害リスクであり、その額は表 8.1 の ESR_M シナリオがそのまま与える。一すなわち本フレームワークの率テーブル出力は、感応度分析だけでなく所要資本のストレス方式計算にも同じ形式でそのまま適用できる。第二に、死亡リスクが 0 となるのは本商品では死亡が脱退 (給付減少) 側に働くためであり、同じ率テーブルを特定疾病死亡保障 (新規性 B) として読む場合には、死亡ストレス +12.5% がクレーム率に直接かかる (ICS_C のレベル部分) という対照が、二層適用の規制上の差異を端的に示す。第三に、規制の標準的手法はここまで一貫して静的なレベルストレスで構成されており、改善トレンドの不確実性 (§8.4 で示した年齢勾配を持つリスク) は第 1 の柱の標準的手法には現れない。トレンドシナリオの定量把握は ORSA・内部管理 (第 2 の柱) と感応度開示 (第 3 の柱) の領域であり、そこが本フレームワークの主たる実装先となる (§9)。

なお本節の計算は、単一商品・給付キャッシュフローのみの簡易ポートフォリオに標準的手法を適用した例示であり、実際の所要資本計算に必要な同質なリスクグループの設定、経費・保険料キャッシュフロー、リスクカテゴリー間統合は含まない。

本章のデモは、方向性が検証された改善率の陽出力 (§6 - §7) が、ESR 適用初年度の実装仕様の上で具体的な感応度の数字に翻訳されることを示した。次章 §9 では、これを実務に導入する際のキャリブレーション指針と導入負担を論じる。

§9 実務ガイドライン (Practical Implementation Guidelines)

§7 でシナリオ生成器として再定位し、§8 でその感応度を数値化した本フレームワークを、実務のアサンプション・ワークフローへ導入する際の指針を本章にまとめる。§9.1 でバックテスト結果 (§5 – §6) に基づく疾病別キャリブレーションとハイパーパラメータ (§3.2.3) のチューニング指針を、§9.2 で「生成器の新設は導入負担が大きいのではないか」という想定反論への体系的な回答と段階的導入パスを、§9.3 で既存システムへの組み込み実績を述べる。

9.1 キャリブレーション・チューニング指針

前提: 二つの経路の分担。§6.5 で切り分けたとおり、疾病別キャリブレーション ($L \cdot P$ の再設定) が支配するのは収束年以降の長期の方向であり、観測終端付近の短期の方向は最新データでの定期再フィット (データ経路) が担う。したがって本節の指針は「 $L \cdot P$ の疾病別設定」と「定期再フィットの運用」をセットで示す。前者だけでは短期方向の誤りは正せず (§6.5 の実験)、後者だけでは収束年以降——保険負債の投影ホライズンで支配的な期間——の整合性が担保されない。

疾病別の長期率 L 。バックテストの結果から帰納した疾病グループ別の指針を表 9.1 に示す (既定は全疾病共通 $L = 1\%$ 、§3.2.3)。

表 9.1: 疾病グループ別の長期率 L キャリブレーション指針

疾病グループ	対象疾病	L の指針	根拠となる検証結果
改善トレンド明瞭	cancer / heart_disease / cerebrovascular / total	既定 1% 維持～2% への 引上げを検討	DA 79.7 – 95.0%($y_c=2014$ 、§6.1)。 cancer は改善の過小外 挿 (正バイアス、§5.1) が あり引上げ余地
悪化転換に注意	diabetes / kidney	0.5～1% に控えめに置く	DA は高い ($y_c=2014$ で 77.7 – 80.5%) が、 COVID 期前後の観測終 端では方向が不安定 (§6.2)
方向反転	liver / hypertensive	0 以下 (0～ – 1%)	既定設定では方向ごと外 す (DA 23.6 – 28.0%、 §6.5)。 $L \leq 0$ への再設定 は長期シナリオ整合性の 必要条件

表 9.1 の適用にあたっては、 L 再設定の効果が現れる期間に留意が要る。反転疾病への $L \leq 0$ は、バックテストの検証期間 (10 年) 内の方向一致率をほとんど変えない (§6.5 表 6.1)。これは指針の欠陥ではなく、検証期間がブレンド区間に含まれ観測終端アンカーが支配するためであり、検証期間内の短期方向は後述の再フィットが、収束年以降の長期方向は L が受け持つという分担の現れである。

収束年 P 。既定は 2035 である。観測終端の改善率が長期想定から大きく乖離している局面——構造ブレイクの直後や方向反転疾病——では、 P を 2025 – 2030 に前倒しし、観測終端アンカーの支配を早期に解いて長期想定への回帰を急ぐことを検討する (§6.5 では $L = 0\%$ に P 前倒しを併用した場合にのみ検証期間内の DA が部分回復した)。逆に、直近トレンドの継続性を重視する局面では既定のままでよい。

平滑化強度 $\lambda_{\text{year}}(\text{lam_col})$ 。既定は 40 である (§3.2.3)。用途で使い分ける。構造変化への追従性を上げたいモニタリング・分析用途では 10 – 20 に下げて観測終端の局所トレンドを尊重させ、前向きの予定率テーブル生成のように率の年次安定性を重視する用途では 60 に強める (§3.2.3 注記の age20 プリセット)。年齢方向 λ_{age} と差分階数 d は本検証の範囲では既定 (40、2) で頑健であった。

定期再フィット。人口動態統計の年次公表に合わせ、年 1 回の再フィットを基本とする。§6.5 のデータ経路が示すとおり、方向反転や構造ブレイクへの短期の自己修正は、キャリブレーション操作ではなく再フィットによって働く (COVID-19 の反映で実証済み。§5.3・§6.2)。再フィットの計算負荷は軽微であり (§9.2 論拠 4)、年次運用の障害にならない。

モデル検証の型。新しい疾病・粒度・商品に適用を広げる際は、本論文の 3 cutoff バックテスト (§4) と方向性的中率 (式 3.12) を雛形として、適用前に DA を計測することを推奨する。§5 – §6 の検証手続きは、そのまま各社のモデル検証のテンプレートとして再利用できる。

9.2 導入負担の分析 —五つの論拠と段階的導入パス

「疾病リスク軸のシナリオ生成器を新設する」という提案 (§7.4) は、ESG の導入がそうであったような大がかりなシステム投資・運用変更を想起させるかもしれない。しかし本フレームワークの導入負担は、次の 5 点の理由で低い。

1. 上流配置・同形式出力。生成器はプロジェクションエンジンの上流に位置し、出力は既存の評価実務が既に消費している形式——年齢 × 暦年 (または年齢 × 経過年) の率テーブル——である。評価モデル・決算プロセス・帳票といった下流工程は無改変で済む。実際、§8 のデモは既存の率パネルとアルゴリズムコアのみで感応度一表に到達しており、評価側に求めたのはシナリオ別率テーブルの読み込みだけであった。
2. 追加ではなく置換。現行実務も、ストレス用の率テーブル (静的表 × 一律係数) を作成する工程を既に持っている。本フレームワークはその工程を置き換えるものであり、シナリオの実行本数を増やさない。一律係数方式で表現できていたレベルショックは本フレームワークでも一律乗算としてそのまま表現でき (表 7.1)、現行方式の出力は本フレームワークの特殊ケースとして再現可能である。
3. 新規データ整備が不要。入力 は 公的統計 (人口動態統計) と、経験率分析のために各社が既に収集している自社経験データで足りる。外部データの新規購入や収集体制の整備を要しない。
4. 計算負荷が軽い。決定論的であるため、ESG のような数千パスの計算・格納基盤を要しない。生成器側 (率テーブルの生成) は Phase 1 fit を全シナリオで共有し、シナリオ追加の限界コストは Phase 2 再投影 1 回にとどまる (§7.2)。評価側 (給付現価計算) に求めるのはシナリオ別率テーブルの読み込みだけであり (論拠 1)、率テーブルは既存の形式と同一であるため (論拠 1・2)、シナリオ本数の増加が既存の評価バッチにもたらす負荷は実行回数に対して線形にとどまる。なお実務プロジェクションモデル上での実行負荷と統合工数の実測は今後の検証に含める (§10.4)。
5. ガバナンス負担が低い。実質的な判断パラメータは L と P 程度であり、いずれも「長期でどの程度の改善が続くと想定するか」「いつ長期想定へ収束させるか」という、経営・検証部門に説明可能な量であ

る。計算は決定論的・再現可能であり、モデル検証は本論文のバックテスト (§4 – §6) がそのまま雛形になる (§9.1)。説明可能性自体が論点となるブラックボックス型の機械学習モデルとは、検証・説明負担の質が異なる。

段階的導入パス。導入にあたって全面切替を迫る必要はなく、リスクの低い用途から段階的に昇格させる設計が可能である。

- 第 1 段階 — 社内の感応度分析・ORSA での試用: 規制計算の外側で、現行の一律係数方式と並行運用し、トレンドシナリオが与える追加情報 (§8.4 の年齢勾配) を内部管理・リスク把握に取り込む。現行実務を一切変更せずに開始できる。
- 第 2 段階 — IFRS 17 感応度開示: $L \pm 50\text{bp}$ 等のグリッド実行 (表 7.1) を開示感応度の計算に用いる。
- 第 3 段階 — ICS / ESR の規制計算: ストレス方式の所要資本計算 (§8.5) へ適用範囲を広げる。

各段階の昇格可否は、§9.1 のバックテスト検証 (適用対象での DA 計測) を通過させることでエビデンスに基づいて判断でき、現行手法との並行運用・比較から入る移行形態が「一律係数からの跳躍」を要求しない緩衝になる。

9.3 既存システムへの組み込み実績

本フレームワークのアルゴリズムコアは、平滑化・投影の純粋関数群 (`fit_scale_bb` / `project_scale_bb`) と設定オブジェクト (`ScaleBBConfig`) からなる小規模な実装である (§3.2)。このコアは、筆者らの経験率集計処理システムへの組み込みが完了しており、自社経験データの集計から疾病別プリセットによる投影率テーブルの生成までを同一ワークフロー内で実行できる。組み込みはコアの複製と設定プリセットの追加のみで行われ、既存の集計・出力工程の改修を要しなかった。経験率分析の既存工程の下流に投影機能が加わるこの形態は、§9.2 の論拠 1(上流配置・同形式出力) と論拠 3(既存データで足りる) を実装レベルで裏付ける事例である。

本章で、シナリオ生成器としての *Scale BB-D* は「どう設定し、どう導入するか」まで具体化された。次章 §10 では、本研究の限界——データの代理性・長期検証可能性・財務デモの簡易性——を正面から整理し、今後の課題への道筋を示す。

§10 限界と今後の課題 (Limitations and Future Work)

本章では、本研究の限界を 5 つの観点に整理し、それぞれに対応する今後の課題を述べる。限界の多くは各章で言及済みであり、ここでは論文全体を通した位置づけと、今後の検証・拡張の具体的な道筋を与える。

10.1 データの代理性 —適用範囲の限定と発生率での直接検証

第一の限界は、入力データの代理性である。本研究が検証したのは死因別死亡率であり、医療保険 (罹患給付) の疾病発生率に対しては方法論検証の代理にとどまる (§3.1.3)。発生率と死因別死亡率のあいだには罹患後死亡率 (致命率) の経年変動が介在するため、水準・トレンドの差は本検証では分離できず、発生率商品への適用は「共通の年齢・世代構造を持つ系列で方法論が検証された」ことを根拠とする間接的なものである。ただしこの限界が及ぶ範囲は発生率商品に限定される。特定疾病死亡保障 (新規性 B) では死因別死亡率がアサンプションそのものであり、代理の問題は生じない (§7.6)。

今後の課題は発生率での直接検証である。発生率そのものの作成という点で本来望ましいのは、健康保険組合のレセプト (診療報酬明細書) や健康診断情報のように個人を経年で追跡できるデータベースを用いる経路である。加入者集団を分母に、疾病別の初発を分子にとることで、受療率や死亡率を介さない発生率を年次・年齢別に作成でき、全疾病について本論文と同型のバックテストが可能になる。ただしこれらは有償のビッグデータとして提供されており、研究目的での利用には費用面の制約が大きいのが現状である。

あわせて、罹患後死亡率 (致命率) は本研究の範囲外であることを再確認する。致命率は分母に罹患数を要し、総人口あたりの死因別死亡率からは得られない。死因別死亡率 $\div$ 実測罹患率による致命率トレンドの推定は将来課題であり、本研究は「罹患後の予後を予測できる」とはいかなる形で主張しない。

10.2 長期予測精度の検証可能性 —蓄積待ちではなくシナリオ化で扱う

第二の限界は、長期率 L の長期効果それ自体の未検証性である。§6.5 で述べたとおり、 $L \cdot P$ が支配するのは収束年以降の方向であり、既定設定 ($P = 2035$) ではその期間の実績はまだ存在しない。10 年のバックテストが検証したのは、ブレンド区間における短期～中期の方向性である。

ただし本研究は、この限界を「データの蓄積を待って検証を完結させる」という枠組みでは扱わない。理由と対処は §6.5 末尾で論じた構図に一貫させる。(i) 限られたデータで検証可能な部分——改善率の方向性——は、本論文の検証で土台として固めた (§6)。(ii) 検証の届かない長期想定は、暗黙の前提としてモデルに埋め込むのではなく、 $L \cdot P$ という解釈可能な陽のパラメータとして明示し、シナリオとして振る対象へ転換した (§7–§8)。(iii) 実績の蓄積を待つ間にも次の構造ブレイク——新たな感染症の流行、医療技術の転換——が混入する以上、蓄積待ちの検証は原理的に完結しない。構造ブレイクに対しては、事後には定期再フィットによる方向の自己修正が働き (§6.5 のデータ経路、COVID-19 で実証済み)、事前には $L \leq 0$ やカタストロフィショックのストレスシナリオとして定量化しておける (表 7.1)。長期の不確実性を点予測的中によって解消しようとするのではなく、検証済みの方向性の上で不確実性を陽に扱う——この構えは経済価値ベース評価の要求構造 (§2.3) と整合的であり、限られたデータしか得られない疾病率アサンプションの信頼性を担保する現実的な方法であると考えている。

10.3 疾病別キャリブレーションの体系化

第三の限界として、§9.1 の疾病別キャリブレーション指針は、8 疾病 × 3 cutoff のバックテストから帰納した暫定的なものである。今後の課題は次の 3 点である。 $L \cdot P$ の選定を、cutoff をずらした擬似外標本での方向性的中率に基づく体系的な選定手続きへ昇格させること。ICD 中分類などより細かい疾病粒度や、5 歳階級より細かい年齢粒度での指針の安定性を確認すること。APC 拡張 (§3.3) の世代効果を含む投影を、同じバックテストの型 (§4) で検証し、コホートショック (§7.2) の実務利用に検証の裏付けを与えること。

10.4 財務デモの簡易性と実務モデルでの再実行

第四の限界は、§8 の BEL 感応度デモが、給付キャッシュフローのみ・脱退独立近似の簡易プロジェクションモデルと 8 つのモデルポイントによるデモである点である。実務水準の財務検証には次が残る。第一に、保険会社での導入実績を持つ実務プロジェクションモデル上での再実行と、率レベル・現価レベルでの突合検証(実行負荷の実測を含む)。第二に、実保有契約ポートフォリオ(契約分布・保険料・事業費・解約動態を含む)での財務インパクト検証。第三に、ESR 実装の未適用部分——リスクカテゴリー間の統合、適格資本と ESR 比率、スプレッド調整(一般バケット等)、および §8.5 で近似にとどめた MOCE・所要資本統合の精緻化——の取り込みである。

10.5 確率論的拡張

最後に、本フレームワークは決定論的シナリオ生成器として設計されており、規制の標準的手法が要求する決定論的ストレス (§2.3) にはそれで足りるが、ORSA におけるリスク分布の把握やリスク選好の定量化には確率論的な把握が資する。改善率残差の分布に基づく L のブートストラップ生成など、検証済みの決定論的な骨格の上に確率層を載せる拡張は自然な発展方向である (§7.4)。経済シナリオ (ESG) との統合——疾病リスク軸と経済リスク軸のシナリオを同一のプロジェクションで消費する運用の体系化——も同じ延長線上にある。

以上の限界は、いずれも本研究の中心的結論——方向性が検証された改善率の陽出力がシナリオ生成器として機能する——を覆すものではなく、その適用範囲と、実務水準へ精緻化していく道筋を規定するものである。次章で本論文の結論を述べる。

§11 結論 (Conclusion)

本論文は、SOA (2012) の死亡率改善スケール Scale BB を全死因死亡率から死因別 (疾病別) 死亡率へ拡張し、人口動態統計 1950–2024 年のパネルを用いた 3 cutoff バックテストで検証した。得られた結果の構造は三段をなす。第一に、当初目的であった点予測の有用性は否定された。Scale BB-D は全 cutoff・全 24 セルで最良の単純ベースラインに MAPE で劣後する ($y_c = 2014$ で +16~+44pp、§5)。第二に、同じ出力を変化の方向で測り直すと、主要 6 疾病の方向性的中率は 77.7–95.0% に達し、方向情報を構造的に持たない・あるいは偶発的にしか持たないベースラインとの乖離が明らかになった (§6)。第三に、この乖離は経済価値ベース評価 (ICS / IFRS 17、日本では ESR) が要求するシナリオ構造の言葉へ翻訳できる。方向性が事前検証された改善率 $i^*(x, y)$ の陽出力は、レベル・トレンド・カタストロフィの各ショック、感応度開示、ORSA ストレスを、同一の fit を共有する設定差し替えだけで内的整合的に生成する (§7)。点予測で勝るベースライン手法は、この役割を構造的に担えない (§7.3)。すなわち Scale BB-D の真価は点予測の代替ではなく、シナリオ生成器である。

この再定位の実務的意義は、§8 の BEL 感応度デモで数値化された。ESR の実装仕様 (無リスク金利カーブ・1 柱告示のストレス係数) に準拠した計算において、規制の一律レベルショック (発生率 +20%) の給付現価への影響が加入年齢によらずほぼ一定 (+17.2~19.1%) であるのに対し、トレンドショック (改善率ゼロ) は 30 歳加入で +31~32%、60 歳加入で +10~11% という明瞭な年齢勾配を持ち、若年契約では規制レベルショックの約 1.7 倍に達する。改善トレンドの不確実性は若年・長期の契約に集中し、静的表 × 一律係数の現行実務はこのリスクの年齢構造を原理的に表現できない。トレンドシナリオを扱えるアサンプション基盤の有無が、ポートフォリオのリスク把握の質を直接左右することを、このデモは規制の語彙の上で示している。

本研究の貢献は二層をなす。新規性 A として、Scale BB 系の改善スケールを死因別死亡率へ拡張し、死因ごとの改善トレンド・期間ショック・世代効果を同一の枠組みで分離抽出する体系を、筆者らの知る限り初めて提示した。新規性 B として、その出力が特定疾病死亡保障——死因別死亡を給付事由とする商品——に対しては代理を介さない直接のアサンプションとなることを示し、医療保険 (発生率への代理適用) と特定疾病死亡保障 (直接適用) という二層の適用対象を確立した。前者では §6 の方向性検証が方法論の検証として、後者では当該アサンプションそのものの検証として働く。

ICS が発効し、日本で ESR の適用が始まった本年は、疾病リスク軸のアサンプション実務がその要求水準を「単一の点予測」から「整合的なシナリオ群」へ切り替える転換点にある。本研究が示したのは、この要求に応える装置が、精度競争で勝つ新しい予測器ではないということである。限られたデータでも検証可能な性質——改善率の方向性——を土台として固め、検証の届かない長期想定を解釈可能な陽のパラメータとしてシナリオ化する枠組みこそが、その装置の要件を満たす。点予測では単純な手法に劣る「暫定スケール」の拡張が、経済価値評価の時代には構造的優位を持つ——この逆説が、バックテストの消極的結論の先に本論文が見出した新知見である。